Conceptos, paradigmas e historia de la IA

Introducción

La pregunta de si una máquina puede ser inteligente no es nueva. Viene desde los primeros días de la computación y todavía no tiene una respuesta definitiva. Lo que sí cambió es el contexto, porque hoy la inteligencia artificial (IA) dejó de ser un tema de nicho para convertirse en algo que atraviesa casi todos los ámbitos de la vida cotidiana y profesional.

> La IA nació como un campo multidisciplinario orientado a desarrollar sistemas capaces de realizar tareas que tradicionalmente requerían inteligencia humana. Se trata de un conjunto de herramientas, algoritmos y métodos que, combinados, permiten que las máquinas aprendan, razonen y tomen decisiones.

De esta forma, se ha consolidado como una disciplina estratégica para el desarrollo científico, tecnológico y productivo. Impulsa transformaciones en ámbitos tan diversos como la automatización, el análisis de datos, la seguridad, la salud, la robótica y la innovación tecnológica. Su impacto es transversal a las tecnologías de la información, la ciencia aplicada y el desarrollo de soluciones para problemas complejos.

A lo largo de su desarrollo, la IA integró conocimientos de la computación, la matemática, la lógica, la estadística, la neurociencia y las ciencias cognitivas, y dio origen a múltiples enfoques para modelar comportamientos inteligentes en máquinas.

El crecimiento de los datos, junto al aumento de la capacidad computacional y el desarrollo de nuevas técnicas de aprendizaje, impulsó saltos cualitativos en disciplinas como el aprendizaje automático, la visión por computadora y el procesamiento del lenguaje natural. Como resultado,

hoy es posible diseñar soluciones capaces de automatizar procesos, asistir en la toma de decisiones, detectar patrones complejos y adaptarse dinámicamente a distintos contextos.

En la actualidad, el debate ya no es solo técnico. A medida que estos sistemas se vuelven más capaces, aparecen preguntas que van mucho más allá del código: quién decide cómo se usan, qué pasa con el trabajo humano, cómo se evitan los sesgos. Su avance continuo redefine la relación entre las personas y la tecnología, abriendo interrogantes que recién están empezando a entenderse.

Caso: Whisper, más allá del reconocimiento de voz

En septiembre de 2022, OpenAI publicó Whisper, un sistema de reconocimiento automático de voz entrenado con 680.000 horas de audio extraídas de internet, capaz de transcribir y traducir 99 idiomas con una tasa de error muy baja. Lo más interesante de Whisper no es únicamente su desempeño técnico, sino lo que permite comprender sobre la forma en que se desarrolla la inteligencia artificial en la actualidad.

Ningún programador indicó explícitamente al sistema cómo reconocer fonemas, distinguir dialectos o interpretar voces con ruido de fondo. Whisper adquirió esas capacidades a partir del análisis masivo de ejemplos de audio y texto, sin recibir reglas específicas sobre cómo suena una vocal o de qué manera varían los acentos entre regiones.

> Este aspecto, que puede parecer solo técnico, marca una diferencia fundamental respecto de gran parte de la computación tradicional porque el conocimiento no fue incorporado de forma manual: fue adquirido mediante aprendizaje a partir de datos.

Este cambio de paradigma ayuda a comprender por qué la IA comenzó a ocupar un lugar central en múltiples disciplinas y sectores productivos. Actualmente, sistemas similares

permiten automatizar tareas, analizar grandes volúmenes de información, asistir procesos de decisión, mejorar interfaces de interacción humano-computadora y desarrollar nuevas herramientas digitales con capacidades cada vez más avanzadas.

Las tecnologías basadas en aprendizaje automático ya forman parte de asistentes virtuales, plataformas de traducción, sistemas de recomendación, herramientas de diagnóstico, mecanismos de detección de fraudes y muchas aplicaciones presentes en la vida diaria.

Whisper usa *transformers*, la misma arquitectura que está detrás de la mayoría de los modelos más potentes de hoy. Lo que lo hace interesante es cómo fue entrenado. Se usó audio tomado directamente de internet, con todo lo que eso implica: errores, ruido, acentos, micrófonos de mala calidad, personas hablando sobre otras personas, variaciones lingüísticas de todo tipo. No hubo un equipo seleccionando cada muestra ni filtrando lo que entraba al modelo; simplemente se tomó lo que había disponible y se usó.

La apuesta era arriesgada porque entrenar con datos sucios suele ser una fuente de problemas. El modelo aprende los patrones útiles y los errores, las inconsistencias, los ruidos que idealmente no deberían estar ahí. Durante mucho tiempo, la práctica estándar era exactamente la contraria: menos datos, pero de mejor calidad y bien controlados. Whisper desafió esa lógica y terminó superando a varios modelos entrenados bajo ese enfoque más tradicional. El volumen, en este caso, compensó las imperfecciones.

Ese resultado refuerza una de las ideas que más peso ganó en la IA de los últimos años. En muchos contextos, tener más datos vale más que tener datos perfectos. No es una regla universal ni aplica para todo, pero con suficiente escala los modelos desarrollan cierta capacidad para filtrar el ruido por sí solos, para encontrar los patrones que importan incluso cuando la información que los rodea es imperfecta. Whisper fue una demostración bastante concreta de eso, y cambió un poco la forma en que se piensa el proceso de entrenamiento en tareas de reconocimiento de voz.

Whisper también pone de manifiesto algunos de los desafíos éticos y sociales asociados a la IA. Parte del audio utilizado para el entrenamiento proviene de contenidos publicados en internet por personas que nunca otorgaron consentimiento explícito para ese uso. Además, el desempeño del sistema no es uniforme en todos los idiomas y dialectos, ya

que los modelos suelen funcionar mejor en aquellos contextos con mayor representación de datos disponibles. De esta manera, la misma tecnología que facilita accesibilidad, automatización y nuevas oportunidades de innovación también plantea interrogantes relacionados con privacidad, sesgos, vigilancia y uso responsable de la información.

A modo de reflexión

Whisper aprendió a transcribir 99 idiomas sin que nadie le enseñara explícitamente las reglas de ninguno de ellos. ¿Qué tipo de inteligencia implica esto? ¿En qué se parece y en qué se diferencia del aprendizaje humano de una lengua? ¿Podría un sistema como Whisper aplicarse en tu área de especialización, y si fuera así, qué riesgos específicos debería considerar?

Anota tu respuesta. Volverás a esta pregunta al final de la lectura para ver cómo evolucionó tu perspectiva.

Definiciones sobre la inteligencia artificial

Inteligencia humana

La inteligencia humana es una capacidad que permite adaptarse a nuevas situaciones, resolver problemas creativamente, comprender conceptos abstractos y manejar relaciones sociales complejas. Incluye la capacidad de introspección y autoconciencia, permitiendo pensar y reflexionar sobre el propio pensamiento. Integra elementos cognitivos, emocionales e intuitivos para interpretar la realidad según proyectos y necesidades (Maureira Cid, 2017).

Esta capacidad cognitiva se manifiesta a través del conocimiento, que constituye el conjunto integrado de información, habilidades y experiencias que una persona acumula y desarrolla a lo largo de su vida. Se manifiesta en dos dimensiones principales: por un lado, el conocimiento explícito, que puede ser fácilmente documentado, transmitido y accedido por otros; y, por otro lado, el conocimiento implícito o tácito, que surge de la experiencia personal y resulta más difícil de formalizar y comunicar. Ambos tipos son complementarios y constituyen la base sobre la cual se interpreta la realidad y se toman decisiones.

Para procesar este conocimiento, los seres humanos emplean el razonamiento, un proceso cognitivo mediante el cual procesan información y aplican reglas lógicas para llegar a conclusiones de manera consciente o inconsciente. Combina diversos mecanismos como el razonamiento deductivo, basado en aplicar principios generales a casos particulares, y el inductivo, que parte de observaciones específicas para formular principios generales.

El razonamiento humano está profundamente influenciado por la intuición, las experiencias previas y el contexto emocional, permitiendo llegar a soluciones que van más allá de la lógica formal. Esta capacidad ayuda a resolver problemas complejos, tomar decisiones en situaciones de incertidumbre y establecer conexiones entre conceptos aparentemente inconexos, demostrando la versatilidad y adaptabilidad del pensamiento humano.

La adquisición y refinamiento de todas estas capacidades se realiza mediante el aprendizaje, un proceso que va más allá de la simple adquisición de información. Se define como la incorporación progresiva de conocimientos, habilidades y competencias que genera transformaciones duraderas en el comportamiento y comprensión del mundo. Ocurre a través de diversas modalidades como la experiencia directa, el aprendizaje por observación e imitación de otros, la educación formal en entornos académicos estructurados y la reflexión profunda sobre nuestras propias experiencias.

Inteligencia artificial

Definir la inteligencia artificial en una sola oración es complicado porque hay demasiadas versiones que compiten entre sí. Russell y Norvig (2016) identifican al menos cuatro familias de definiciones que convivieron a lo largo de la historia del campo.

La pregunta que da origen a estas definiciones es doble: si el sistema piensa o actúa, y si lo hace como un humano o de manera racional.

- Un sistema que piensa como un humano intenta replicar el proceso cognitivo tal como ocurre en las personas, que es la visión desde la que trabajan las ciencias cognitivas y la psicología computacional.

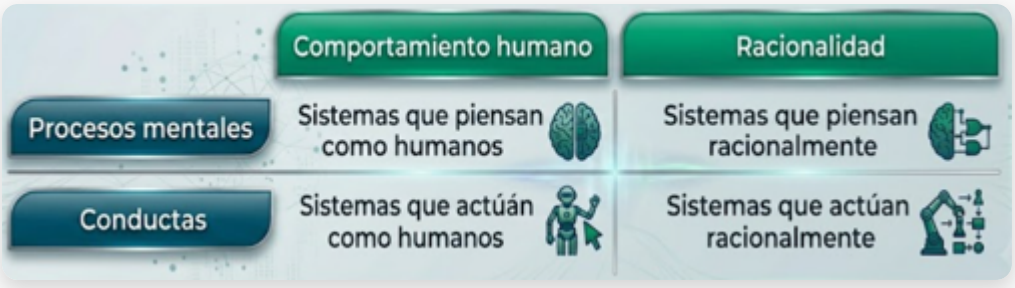
- Un sistema que piensa racionalmente no se preocupa por imitar al humano, se preocupa por aplicar reglas de inferencia lógicamente correctas, que es la tradición de la lógica formal.

- Un sistema que actúa como un humano busca comportarse de forma indistinguible de una persona, que es la intuición detrás del Test de Turing.

- Un sistema que actúa racionalmente simplemente intenta maximizar el logro de sus objetivos a partir de lo que percibe del entorno.

Vale aclarar que racional implica que el sistema elige la acción que, dado lo que sabe y lo que percibe, tiene más opciones de llevar al mejor resultado posible. No importa cómo llega a esa decisión, si por reglas, por estadística o por redes neuronales. Lo que importa es que no actúa al azar: hay una lógica detrás orientada a maximizar un objetivo. Por ejemplo, un sistema de recomendación no entiende las películas que sugiere, pero tampoco elige al azar: dado lo que sabe de los gustos del usuario, selecciona lo que tiene más posibilidades de ser visto por este. Eso es actuar racionalmente.

Figura 1. Familias de definiciones



Fuente: elaboración propia con base en Russell y Norvig (2016).

Las tres primeras familias tienen algunas limitaciones que frenaron su adopción:

- La que piensa como un humano exige entender cómo funciona el cerebro de verdad, algo que todavía no se comprende en su totalidad.
- La que piensa racionalmente es compleja de aplicar por la ambigüedad del mundo real, ya que la lógica formal necesita problemas bien definidos para funcionar.
- La que actúa como un humano pone a la persona como referencia; entonces, un sistema que resuelve algo de una manera distinta quedaría afuera, aunque el resultado sea igual o mejor.

La cuarta no tiene ese problema. No pide imitar al humano ni usar lógica pura, solo que el sistema tome las mejores decisiones posibles dado lo que percibe. Eso la hace aplicable a casi cualquier cosa: un ajedrecista, un filtro de spam, un auto autónomo, un modelo de lenguaje; todos actúan para maximizar algún objetivo, cada uno a su manera. Por eso es la que terminó dominando la práctica y la que será eje conceptual a lo largo de esta materia.

Este enfoque se basa en el concepto de agente racional, definido por Russell y Norvig (2016) como la unidad de análisis fundamental de la IA moderna. Un agente es aquello que percibe su entorno y

actúa sobre él. Su racionalidad no radica en imitar el pensamiento humano, sino en seleccionar la acción que, considerando su conocimiento y sus percepciones, maximiza su rendimiento esperado.

La definición es lo suficientemente amplia como para incluir cosas muy distintas. Un termostato percibe la temperatura y actúa sobre la calefacción. Un sistema de recomendación percibe el historial de un usuario y decide qué mostrarle. Ambos son agentes en ese sentido técnico, aunque claramente no son lo mismo ni tienen el mismo nivel de complejidad. El concepto no implica inteligencia por sí solo, sino una estructura de funcionamiento que la IA toma como punto de partida.

Con esa definición como base, vale la pena detenerse en qué implica concretamente. Durante mucho tiempo, la forma más común de explicar la IA fue decir que busca crear sistemas capaces de hacer cosas que normalmente requerían inteligencia humana: razonar, aprender, resolver problemas. Es una definición intuitiva y no está mal como punto de partida.

Pero la inteligencia humana es producto de millones de años de evolución biológica, con todo lo que eso implica: emociones, intuición, contexto social, experiencia corporal. Pretender que una máquina replique eso es ambicioso, como verás más adelante.

> Lo que la IA aprendió es que no hace falta imitar al humano para ser útil, o incluso para superarlo en tareas específicas. Por eso la definición del agente racional terminó siendo la más productiva: no compite con la inteligencia humana ni intenta copiarla, simplemente opera bajo su propia lógica para maximizar sus objetivos. Lo que sí comparten es la capacidad de analizar información, detectar patrones y actuar en consecuencia, aunque los mecanismos detrás sean completamente distintos.

Para eso, la IA integró a lo largo de su historia conocimientos de la computación, la matemática, la lógica, la estadística, la neurociencia y las ciencias cognitivas, dando origen a múltiples enfoques y herramientas que, combinados, permiten que las máquinas aprendan, razonen y tomen decisiones.

El razonamiento en IA es el proceso por el cual un sistema llega a una conclusión o toma una decisión a partir de la información que tiene disponible. No hay consciencia detrás de ese proceso,

es fundamentalmente computacional, pero los resultados pueden ser sorprendentemente parecidos a los de un razonamiento humano.

El aprendizaje funciona de manera similar: un sistema aprende cuando mejora su rendimiento en una tarea a partir de la experiencia, sin que nadie le haya programado explícitamente cada situación posible. En lugar de seguir un algoritmo fijo, ajusta sus parámetros internos en respuesta a nuevos datos, lo que le permite volverse más preciso con el tiempo.

La ventaja más clara de estos sistemas es su capacidad para procesar volúmenes enormes de información con una velocidad y precisión que el cerebro humano no puede igualar. Pero también tienen límites concretos: operan dentro de estructuras definidas y carecen de intuición, creatividad espontánea y comprensión del contexto emocional o social. Pueden ser muy buenos en tareas específicas y bastante torpes fuera de ellas.

Un robot que ensambla piezas con precisión milimétrica puede no saber qué hacer ante un componente ligeramente distinto al que fue entrenado. Un modelo predictivo puede encontrar patrones en millones de registros clínicos y aun así no detectar que una variable fue mal cargada.

Un sistema de detección de intrusiones puede identificar patrones de ataque conocidos, pero quedar ciego ante una amenaza nueva. Un algoritmo de recomendación puede optimizar las ventas de un producto sin entender nada del negocio que lo usa.

Entender dónde termina la utilidad del sistema y dónde empieza el juicio humano es, en buena medida, lo que distingue a quien simplemente usa estas herramientas de quien las diseña, las evalúa o decide cuándo confiar en ellas.

Automatización, algoritmos y sistemas inteligentes

Una de las confusiones más comunes es tratar como equivalentes conceptos que son cualitativamente distintos. No todo sistema que hace algo es inteligente, y no todo sistema inteligente aprende de la misma manera. Aclarar estas diferencias es clave para entender cómo se diseña, se evalúa y se confía en un sistema.

El punto de partida es la automatización tradicional, que ejecuta secuencias de acciones predefinidas sin posibilidad de desviación. Un proceso automatizado de facturación, un sistema de backup nocturno o una alarma programada con horario fijo operan a partir de instrucciones que un humano codificó completamente: no aprenden, no toman decisiones en ningún sentido real y fallan ante cualquier situación que no fue anticipada. Su mayor virtud es la predictibilidad total; su principal limitación es exactamente la misma.

Los algoritmos clásicos agregan lógica de decisión, pero siguen siendo determinísticos, es decir, que para la misma entrada siempre producen la misma salida. Un algoritmo de ordenamiento, un motor de búsqueda basado en palabras clave o un sistema de navegación GPS con grafos son herramientas útiles dentro del dominio para el que fueron diseñados, pero no generalizan más allá de lo que su programador anticipó y no mejoran con la experiencia.

Los sistemas inteligentes dan un salto cualitativo al incorporar la capacidad de aprender a partir de datos, generalizar ese aprendizaje a situaciones nuevas y, en muchos casos, continuar actualizándose durante la operación. Un clasificador de imágenes aprende patrones estadísticos a partir de miles de ejemplos etiquetados y puede reconocer objetos en imágenes que nunca vio. Whisper aprendió a transcribir habla en docenas de idiomas sin que nadie le programara las reglas fonológicas de ninguno de ellos.

Un sistema de detección de intrusiones puede actualizar sus modelos con nuevos datos de tráfico y responder a amenazas que no existían cuando fue entrenado. Lo que distingue a estos sistemas no es que sigan instrucciones más sofisticadas, sino que construyen sus propias representaciones internas del problema y las refinan con la experiencia.

Figura 2. Progresión de capacidad en sistemas computacionales



Fuente: elaboración propia.

Esta distinción tiene consecuencias prácticas directas. Saber en qué categoría cae un sistema es el punto de partida para entender qué puede hacer, qué no puede hacer y cuándo conviene confiar en él.

- En ciencia de datos, un sistema basado en reglas explícitas podría rechazar una transacción bancaria porque supera un monto fijo definido por un analista, mientras que uno basado en modelos aprendidos detecta que esa misma transacción es sospechosa porque rompe el patrón de comportamiento habitual de ese usuario específico, aunque el monto sea normal.

- En seguridad informática, un firewall con reglas fijas bloquea lo que ya se sabe que es peligroso, pero un atacante que usa una técnica nueva pasa sin problemas; un sistema inteligente puede detectar que algo raro está ocurriendo aunque nunca haya visto ese tipo de ataque antes.

- En bioinformática, la diferencia existe entre buscar una mutación genética que ya se conoce y se sabe dónde mirar, y entrenar un modelo que analiza miles de secuencias y

encuentra por sí solo un patrón que nadie había identificado previamente.

- En robótica, un brazo industrial programado para soldar una pieza específica se detiene o falla si la pieza llega unos milímetros desplazada, mientras que un sistema inteligente percibe el desplazamiento y ajusta su movimiento en consecuencia.

- En innovación y desarrollo de productos, la diferencia aparece cuando una empresa usa un formulario fijo para recibir feedback de sus usuarios versus un sistema que analiza miles de comentarios, detecta patrones de insatisfacción que nadie había notado y sugiere en qué dirección debería evolucionar el producto.

IA débil y fuerte

Dentro del campo de la IA existe una distinción fundamental entre dos grandes tipos de sistemas. La IA débil, también llamada específica, agrupa a todos los sistemas diseñados para hacer una sola cosa bien: reconocer imágenes, traducir texto, detectar fraudes o transcribir habla. No comprenden lo que hacen ni pueden aplicar ese conocimiento a otra tarea.

La IA fuerte, en cambio, refiere a un sistema hipotético con inteligencia general comparable a la humana, capaz de aprender y razonar sobre cualquier problema con la misma facilidad con la que una persona pasa de leer un contrato a aprender a cocinar.

> Russell y Norvig (2016) son categóricos en cuanto a que todos los sistemas de IA que existen en la actualidad son débiles. Por más impresionante que sea el desempeño de GPT-4 en exámenes de derecho o medicina, o de un sistema de reconocimiento facial que identifica personas en milisegundos, ninguno puede hacer algo para lo que no fue entrenado.

Un modelo que traduce con precisión entre decenas de idiomas no puede usar ese mismo conocimiento para aprender a manejar un auto o interpretar una radiografía. No le falta

información, pero su capacidad está estructuralmente limitada al problema para el que fue construido.

La IA fuerte permanece como un horizonte todavía no alcanzado, aunque el debate sobre si los modelos actuales se acercan o no a ella está abierto y es genuinamente complejo. Hay quienes argumentan que los modelos de lenguaje más recientes muestran señales de una capacidad más general; hay quienes responden que esa apariencia es engañosa y que en el fondo estos sistemas siguen siendo muy buenos para reconocer patrones sin entender nada de lo que procesan.

Lo que sí es claro es que la pregunta tiene consecuencias concretas sobre cómo se regulan estos sistemas, cómo se evalúan sus riesgos y qué nivel de autonomía se les puede dar. Para quienes van a diseñar, auditar o tomar decisiones sobre sistemas de IA, entender esta distinción es tan importante como conocer los algoritmos que los hacen funcionar.

IA predictiva y generativa

Otra distinción importante es la que separa la IA predictiva de la IA generativa, dos modos de operación bien diferenciados que hoy conviven en la mayoría de las aplicaciones.

La IA predictiva analiza datos existentes para estimar un resultado; determina si un correo es spam, si una transacción es fraudulenta o si un paciente es probable que abandone un tratamiento. No produce nada nuevo, solo clasifica, ordena o anticipa a partir de lo que ya ocurrió.

Su lógica es siempre la misma: toma un conjunto de datos de entrada, los procesa y devuelve una estimación sobre algo que todavía no se sabe con certeza. Cuanto mejor entrenado está el modelo y más representativos son los datos con los que aprendió, más confiable es esa estimación. Pero en ningún caso el sistema está creando algo, sino que está calculando.

La IA generativa, en cambio, produce contenido que antes no existía. No predice qué va a pasar: construye algo a partir de patrones que aprendió durante su entrenamiento. Un modelo de lenguaje genera texto, un modelo de imagen genera imágenes, un modelo de código genera funciones.

Lo que produce puede ser sorprendentemente bueno, pero no proviene de una comprensión del problema. Proviene de haber visto suficientes ejemplos como para aprender a imitar su estructura. Esa diferencia importa porque define también sus límites, ya que un sistema generativo puede producir algo que parece correcto, pero no lo es, y detectar ese error requiere criterio externo porque el sistema no tiene forma de saber si lo que produjo es verdadero o útil.

Lo relevante es que en la práctica estas dos capacidades aparecen cada vez más combinadas. Por ejemplo:

- ✓ Un sistema de seguridad informática puede detectar si un comportamiento es sospechoso y al mismo tiempo generar un reporte en lenguaje natural explicando qué indicadores activaron la alerta.
- ✓ Un sistema de análisis clínico puede estimar el riesgo de una enfermedad y sugerir opciones de tratamiento adaptadas al perfil del paciente.
- ✓ En bioinformática, un modelo puede predecir la función de una proteína y otro puede generar candidatos moleculares con propiedades específicas para un tratamiento.
- ✓ Un equipo de desarrollo de producto puede usar un modelo que identifica qué funcionalidades generan más problemas y otro que propone alternativas de diseño para resolverlos.

En todos estos casos hay un componente que anticipa y otro que produce, y entender cuál es cuál importa porque tienen lógicas de construcción, validación y tipos de error completamente distintos. Un modelo predictivo que falla lo hace de maneras relativamente predecibles y medibles. Un modelo generativo que falla puede producir algo que parece completamente razonable y aun así estar equivocado.

Experimentación: explorando límites

Explora los límites de un modelo de lenguaje para entender en la práctica la diferencia entre IA débil e IA fuerte, y entre capacidades reales y apariencias de inteligencia.

Plataforma: Registrar cuál IAG se utiliza.

Prompt sugerido: Hazme tres preguntas seguidas sobre el mismo tema que yo elija. Primero, responde tú mismo la pregunta 1. Antes de responder la pregunta 2, dime si recuerdas exactamente lo que dijiste en la respuesta 1 o si necesitarías releerla. Luego responde la pregunta 2 y repite el proceso para la pregunta 3. El tema que elijo es: [escribe un tema de tu carrera específica].

Reflexión: ¿El modelo fue honesto sobre sus limitaciones de memoria? ¿Qué implicancias tiene esta característica si debes decidir usar el modelo como herramienta en tu campo profesional?

Evolución histórica de la inteligencia artificial

La historia de la inteligencia artificial está arraigada en expectativas. Cada gran avance fue seguido de promesas que superaban lo alcanzable con las herramientas de la época, lo cual generó decepciones, recortes de financiamiento y períodos de relativo estancamiento que los historiadores del campo denominan inviernos. Entender este patrón no es meramente un ejercicio histórico: cultivar ese escepticismo calibrado es lo que distingue a un profesional maduro de uno que oscila entre el entusiasmo acrítico y el rechazo injustificado.

El nacimiento de la IA como disciplina (1950–1970)

El punto de partida más citado es 1950, cuando el matemático Alan Turing publicó *Computing Machinery and Intelligence*. Turing no intentó definir la IA directamente porque la consideraba una pregunta filosófica. Por ello, propuso un criterio operacional: si un juez humano, manteniendo una conversación exclusivamente textual, no puede distinguir entre una persona y una máquina, entonces esa máquina puede considerarse inteligente. La célebre Prueba de Turing nunca fue adoptada como estándar de investigación, pero la pregunta que articula, ¿puede pensar una máquina?, sigue vigente para evaluar el desempeño de los modelos actuales.

Seis años después, en 1956, John McCarthy organizó el *Dartmouth Summer Research Project*, un encuentro que congregó a figuras de la época. La propuesta de trabajo partía de una suposición optimista, y es que todos los aspectos de la inteligencia podían ser descritos con suficiente precisión como para que una máquina los simulara.

Fue McCarthy quien acuñó el término inteligencia artificial, y esa convicción moldeó las dos décadas siguientes bajo el paradigma simbólico, es decir, la idea de que pensar es esencialmente manipular símbolos según reglas formales (Russell y Norvig, 2016).

Los primeros resultados fueron prometedores en dominios acotados. Algunos programas demostraban teoremas matemáticos; otros jugaban al ajedrez con nivel aficionado o resolvían problemas de álgebra. Estos logros, impresionantes para la época, alimentaron predicciones sobre la inminente llegada de una IA equivalente a la humana. Los autores manifiestan que esa inexactitud se pagaría caro, dado que las expectativas infladas sembraron el terreno para las primeras grandes decepciones.

Sistemas expertos y el primer invierno de la IA (1970–1990)

El paradigma simbólico alcanzó su expresión más madura en los sistemas expertos, programas que codificaban el conocimiento de especialistas mediante reglas de producción del tipo si condición, entonces acción. Sin embargo, el paradigma chocó con una limitación que sus promotores habían subestimado sistemáticamente, concretamente el problema de la adquisición del conocimiento.

Codificar el conocimiento humano en reglas explícitas resulta costoso, produce sistemas frágiles ante situaciones apenas fuera de su dominio de entrenamiento y escala con dificultad, ya que agregar nuevo conocimiento muchas veces contradice reglas preexistentes y genera inconsistencias difíciles de detectar. Además, gran parte del conocimiento experto es tácito, ya que los especialistas lo poseen y lo aplican, pero no pueden articularlo en proposiciones formales, y ese tipo de saber es prácticamente imposible de capturar en un conjunto de reglas (Russell y Norvig, 2016).

El resultado fue el primer invierno de la IA, aproximadamente entre 1974 y 1980, cuando las agencias de financiamiento recortaron drásticamente sus inversiones ante la evidencia de que las promesas no se materializaban. Este período forzó a los investigadores a replantear sus supuestos de base y buscar enfoques más modestos y, en última instancia, más robustos. Un segundo invierno, menos profundo pero igualmente significativo, ocurrió entre 1987 y 1993. El mercado de los sistemas expertos colapsó ante sus propias limitaciones prácticas (Kambhampati et al., 2020).

El surgimiento del aprendizaje automático (1990–2010)

La respuesta al fracaso del paradigma simbólico fue un cambio radical de perspectiva. En lugar de intentar codificar el conocimiento, se buscó que el sistema lo aprenda a partir de datos. Esta transición no fue abrupta, dado que muchas de las ideas centrales del aprendizaje automático existían desde los años 60 y 70, pero resultó decisiva para la evolución posterior del campo (Russell y Norvig, 2016).

El *machine learning* invierte la lógica de la programación tradicional. En lugar de escribir reglas que determinen si un correo es spam, se le proporcionan al sistema miles de ejemplos ya clasificados y se le permite identificar los patrones estadísticos que los distinguen. Las consecuencias de este cambio son profundas, ya que el rendimiento del sistema depende de la calidad y cantidad de los datos de entrenamiento. Por eso el aprendizaje automático despegó en paralelo con la digitalización masiva de la información, ya que más datos disponibles significó modelos más capaces (Raschka y Mirjalili, 2017).

Durante los años 90 y la primera década del 2000, las máquinas de soporte vectorial, los árboles de decisión y métodos de *ensemble* como *Random Forest* se consolidaron como las herramientas dominantes del campo. El surgimiento de bibliotecas como *scikit-learn* democratizó el acceso a estas técnicas, de modo que cualquier profesional con conocimientos básicos de Python podía implementar clasificadores, regresores y algoritmos de *clustering* sobre sus propios datos. Este ecosistema transformó el aprendizaje automático de un campo de investigación especializado en una competencia técnica ampliamente distribuida en la industria.

Las aplicaciones se multiplicaron. En robótica, la navegación probabilística permitió que los robots mantuvieran distribuciones de probabilidad sobre su posición en el entorno, actualizándolas continuamente con nuevas lecturas de sensores, un enfoque radicalmente distinto al de construir un mapa exacto y estático del mundo.

En bioinformática, los modelos ocultos de Markov se convirtieron en herramientas fundamentales para el análisis de secuencias genómicas (Raschka y Mirjalili, 2017). En seguridad, los primeros detectores de *spam* basados en aprendizaje automático comenzaron

a reemplazar los filtros de palabras clave, aprendiendo a adaptarse a las tácticas cambiantes de los emisores de correo malicioso.

La revolución del deep learning y el rol del hardware (2010–2020)

El año 2012 marca una discontinuidad clara. En septiembre de ese año, un equipo de investigadores presentó una red neuronal profunda en la competencia de clasificación de imágenes más importante de la época, reduciendo la tasa de error del 26% al 15% (Krizhevsky, Sutskever y Hinton, 2017). Ninguna técnica previa había logrado una mejora de tal magnitud en una sola iteración. La diferencia técnica era, en apariencia, simple: una red con muchas capas entrenada sobre unidades de procesamiento gráfico en lugar de procesadores convencionales. Pero sus implicaciones fueron revolucionarias.

Las GPUs (*graphics processing unit*, unidades de procesamiento gráfico), originalmente diseñadas para renderizar imágenes en videojuegos, resultan ideales para las operaciones de álgebra lineal masiva que requiere el entrenamiento de redes neuronales, ya que ejecutan miles de multiplicaciones matriciales en paralelo.

Esto redujo el tiempo de entrenamiento y abrió la posibilidad de entrenar redes con decenas de millones de parámetros, algo que antes era computacionalmente prohibitivo. Las ideas fundamentales del *deep learning*, entre ellas las redes con múltiples capas y el algoritmo de *backpropagation*, existían desde los años 80; lo que cambió fue la disponibilidad de hardware adecuado y de datos suficientes para entrenar modelos a esa escala.

Se trata de un recordatorio importante: en IA, las ideas y la infraestructura evolucionan en planos distintos, y a veces basta que la segunda alcance a las primeras para desencadenar un salto cualitativo.

El impacto se extendió a múltiples campos:

- ✓ En bioinformática, el *deep learning* permitió aprender representaciones directamente desde secuencias de ADN o ARN, eliminando gran parte del preprocesamiento manual (Krizhevsky et al., 2017).

- ✓ En seguridad informática, las redes profundas hicieron posible detectar *malware*

- analizando código binario sin necesidad de firmas predefinidas.

- En ciencia de datos, las redes recurrentes y convolucionales se convirtieron en herramientas estándar para series temporales e imágenes, respectivamente.

- En robótica, la visión computacional basada en redes profundas permitió a vehículos autónomos y robots de servicio operar en entornos no controlados con una confiabilidad antes inalcanzable.

- Para desarrolladores e innovadores tecnológicos, las APIs de visión y procesamiento de lenguaje que comenzaron a ofrecer Google, Amazon y Microsoft entre 2016 y 2020 democratizaron el acceso a estas capacidades sin requerir formación en investigación.

Modelos fundacionales e IA generativa (2020–presente)

La siguiente disrupción llegó en 2020 con la publicación de GPT-3, un modelo de lenguaje con 175.000 millones de parámetros que demostró algo que la teoría no había previsto: escalar los datos y el cómputo no solo produce mejoras cuantitativas, sino también cualitativas en las capacidades del sistema.

A diferencia de todos los modelos anteriores, GPT-3 podía realizar tareas para las que no había sido entrenado explícitamente, simplemente a partir de unos ejemplos incluidos en el *prompt*. Este momento marca el inicio de la era de los modelos fundacionales: son sistemas entrenados a escala masiva y sirven como base para construir aplicaciones específicas mediante ajuste fino o instrucción directa (Bommasani, Hudson, Aditi, Altman, Arora, Koreeda y Liang, 2021).

La IA generativa abarca modelos de texto, modelos de imagen, modelos de audio y modelos de código. Este conjunto de herramientas ha transformado radicalmente lo que un profesional puede hacer con la IA sin necesidad de experiencia técnica profunda. La barrera de entrada se ha desplazado y ya no es necesario saber entrenar un modelo, solo se debe saber usarlo bien.

Al mismo tiempo, esta generación de sistemas introduce desafíos nuevos, como las alucinaciones o generación de información falsa que es aparentemente verdadera, la amplificación de sesgos presentes en los datos de entrenamiento, los riesgos de privacidad derivados de la memorización de datos y superficies de ataque inéditas como la inyección de instrucciones en el *prompt*, que no existían con los paradigmas anteriores.

Comprender esto es la base sobre la que se construye el juicio profesional necesario para evaluar qué pueden hacer hoy estos sistemas, dónde fallan de manera predecible, y por qué las promesas más extravagantes merecen exactamente el mismo escepticismo calibrado que las de 1956.

Paradigmas de la inteligencia artificial

Hablar de paradigmas en IA es más útil que hablar de generaciones porque captura algo que la historia confirma: que los enfoques no se reemplazan limpiamente, sino que coexisten, compiten y se complementan. En la actualidad, en aplicaciones de alta complejidad se encuentran sistemas que combinan razonamiento lógico explícito con modelos estadísticos y capas de inferencia probabilística. Analizar cada paradigma por sus propios méritos es una competencia profesional esencial.

IA simbólica

El paradigma simbólico parte de una premisa central: es posible representar formalmente el conocimiento humano en lógica de predicados, en reglas de producción o en ontologías estructuradas, y manipularlo computacionalmente para derivar conclusiones correctas.

Las ventajas son importantes en ciertos contextos. La IA simbólica produce razonamiento explicable, porque se puede trazar paso a paso cómo el sistema llegó a una conclusión. Funciona con pocos datos si el conocimiento del dominio puede codificarse con precisión, y es resistente a distribuciones de datos inusuales que habrían confundido a un modelo estadístico.

En seguridad informática, los sistemas de reglas para detección de intrusiones siguen siendo relevantes precisamente porque permiten a los analistas entender exactamente qué patrón activó una alerta, un requisito legal en muchos contextos regulatorios.

Las limitaciones son igualmente reales. El conocimiento tácito, es decir, el que los expertos poseen, pero no pueden articular, es difícil de codificar en reglas. La escala es un problema fundamental, dado que sistemas con miles de reglas interactuando generan comportamientos emergentes difíciles de predecir y mantener. Y la fragilidad ante situaciones ligeramente fuera del dominio anticipado es un riesgo permanente, ya que una regla que no fue escrita para una situación específica simplemente no funciona, sin posibilidad de adaptación gradual (Russell y Norvig, 2016).

IA subsimbólica

El paradigma subsimbólico abandona la representación explícita del conocimiento. En lugar de codificar reglas, entrena modelos que aprenden representaciones internas a partir de ejemplos. Las redes neuronales son el arquetipo de este enfoque, compuestas por capas de nodos interconectados que ajustan sus pesos mediante el algoritmo de *backpropagation* para minimizar el error en una tarea de predicción o clasificación.

Lo que hace poderoso al enfoque subsimbólico es su capacidad de descubrir patrones que ningún humano habría sabido codificar a priori:

- En detección de fraude financiero, por ejemplo, un modelo entrenado sobre millones de transacciones puede identificar combinaciones sutiles de variables que ningún analista habría pensado en combinar manualmente, y hacerlo en tiempo real sobre cada nueva operación.
- En robótica, las redes profundas permiten que un robot aprenda políticas de control directamente desde imágenes de cámara, sin necesidad de que un ingeniero defina explícitamente qué características del entorno son relevantes.
- En ciencia de datos, demuestran cómo redes de *embedding* aprenden representaciones semánticas de texto que capturan relaciones de significado complejas sin ninguna codificación manual.

La contrapartida principal es la opacidad. Los pesos de una red neuronal profunda no tienen interpretación directa, lo que dificulta entender por qué el modelo toma determinadas decisiones, un problema conocido como caja negra.

Esto es especialmente problemático en seguridad informática, donde se necesita saber qué patrón activó una alerta para poder actuar sobre ella; en bioinformática clínica, donde una predicción errónea puede tener consecuencias para pacientes reales; y en cualquier contexto donde existan requerimientos legales o regulatorios de explicabilidad de las decisiones automáticas.

La interpretabilidad de modelos, conocida como inteligencia artificial explicable o XAI, es uno de los campos de investigación más activos precisamente para mitigar esta limitación (Raschka y Mirjalili, 2017).

IA probabilística

La incertidumbre no es una excepción en los problemas del mundo real, sino la regla. Los sensores de un robot miden con ruido. Los síntomas de una enfermedad pueden corresponder a múltiples diagnósticos. Un paquete de red con características sospechosas puede ser malicioso o simplemente inusual. Murphy (2022) argumenta que la IA probabilística ofrece el marco formal más riguroso para razonar coherentemente bajo estas condiciones, basado en la teoría de la probabilidad y en particular en el teorema de Bayes.

En lugar de producir respuestas categóricas, un sistema probabilístico produce distribuciones de probabilidad sobre posibles respuestas. En lugar de afirmar que un paquete de red es malicioso, estima que hay un 87% de probabilidad de que lo sea dado el patrón de tráfico observado.

Esta cuantificación de confianza permite tomar decisiones racionales que incorporan el costo asimétrico de diferentes tipos de error. En seguridad, ignorar un ataque real tiene consecuencias muy distintas a generar una falsa alarma, y esa diferencia puede incorporarse formalmente solo si el sistema trabaja con probabilidades.

En bioinformática, los modelos ocultos de Markov han sido fundamentales durante décadas para el análisis de secuencias genómicas, permitiendo modelar la probabilidad de que una secuencia de nucleótidos corresponda a una región codificante o no codificante e incorporando de manera natural la incertidumbre inherente a los procesos biológicos.

Murphy (2022) describe cómo los modelos de grafos probabilísticos extienden este enfoque para capturar dependencias complejas entre variables, con aplicaciones directas en el análisis de redes

regulatorias genéticas. En robótica, los filtros de partículas y los filtros de Kalman son componentes estándar en los sistemas de navegación autónoma, permitiendo que un robot estime su posición a partir de lecturas ruidosas de sensores y actualice esa estimación continuamente a medida que se mueve.

Vale subrayar que el aprendizaje profundo y el razonamiento probabilístico no son enfoques antagónicos. Los modelos generativos modernos tienen interpretaciones probabilísticas precisas, y los sistemas más sofisticados integran ambas perspectivas de manera creciente (Murphy, 2022).

Aprendizaje por refuerzo

El aprendizaje por refuerzo constituye un paradigma con identidad propia. A diferencia del enfoque subsimbólico tradicional, que aprende a partir de ejemplos etiquetados, y del simbólico, que parte de reglas predefinidas, el aprendizaje por refuerzo sitúa a un agente en interacción directa con un entorno.

El agente no recibe instrucciones explícitas sobre qué hacer, sino señales de recompensa o penalización según las consecuencias de sus acciones, y ajusta su comportamiento progresivamente para maximizar la recompensa acumulada a lo largo del tiempo (Russell y Norvig, 2016).

La intuición central es cercana a cómo aprenden muchos organismos biológicos mediante prueba y error. Un robot que aprende a caminar sin que nadie le muestre cómo hacerlo, o un agente que aprende a jugar al ajedrez disputando millones de partidas contra sí mismo, son ejemplos representativos de este paradigma. En ambos casos, el sistema no parte de conocimiento previo codificado, sino que construye su propia política de comportamiento a partir de la experiencia acumulada.

Para las ingenierías, este paradigma resulta especialmente relevante porque conecta de manera natural con la teoría de control y los sistemas dinámicos, campos en los que la idea de un agente que regula su comportamiento en función de retroalimentación del entorno es central.

En ciencia de datos y desarrollo de productos tecnológicos, el aprendizaje por refuerzo sustenta sistemas de recomendación, optimización de recursos y agentes conversacionales que se adaptan

al comportamiento del usuario. Los aspectos técnicos de este paradigma se desarrollan en profundidad más adelante en el curso (Russell y Norvig, 2016).

IA híbrida

El paradigma híbrido parte de que los problemas complejos del mundo real rara vez caben perfectamente en un solo enfoque. Un asistente de conducción autónoma, por ejemplo, podría combinar un modelo de visión artificial para detectar peatones y señales de tráfico, un planificador simbólico que aplica las reglas de tránsito de manera explícita y un módulo probabilístico que estima la intención de otros conductores a partir de su trayectoria observada para anticipar situaciones de riesgo. Ninguno de estos tres componentes resolvería el problema por sí solo con el mismo nivel de confiabilidad que su combinación.

Kambhampati et al. (2020) señalan que la investigación en IA híbrida ha ganado interés en los últimos años, especialmente porque los sistemas puramente subsimbólicos frecuentemente fallan ante la necesidad de incorporar conocimiento previo estructurado o de explicar sus decisiones de manera auditable.

La robótica muestra con claridad cómo estos paradigmas convergen en la práctica. Cuando un robot autónomo recibe la instrucción de buscar un objeto en una habitación desconocida, necesita entender el lenguaje natural de la instrucción, reconocer visualmente los objetos a su alrededor, estimar su propia posición en el espacio con sensores imperfectos y descomponer el objetivo en una secuencia de acciones concretas.

Ninguno de esos problemas pertenece al mismo paradigma, y ninguno puede resolverse ignorando los demás. Los modelos de lenguaje de gran escala se incorporan a estas arquitecturas para manejar la comprensión de instrucciones complejas, una capacidad que los módulos de planificación clásica simplemente no tenían.

Tabla 1. Características centrales de los cuatro paradigmas

Paradigma	Fundamento	Fortaleza	Limitación
Simbólico	Reglas y lógica explícita.	Explicabilidad, pocos datos.	Difícil de escalar.
Subsimbólico	Aprendizaje desde datos.	Patrones complejos, gran escala.	Opacidad, necesita muchos datos.
Probabilístico	Inferencia estadística bayesiana.	Cuantifica incertidumbre.	Cómputo de inferencia exacta.
Híbrido	Integración de enfoques.	Flexibilidad y robustez.	Complejidad de diseño.

Fuente: elaboración propia.

Comprender estos paradigmas como herramientas con fortalezas y limitaciones propias es lo que permite, ante un problema concreto, seleccionar el enfoque más adecuado o diseñar la combinación que mejor lo resuelva. Esa capacidad de juicio es, en última instancia, una de las competencias más valiosas a desarrollar.

Reflexiona

Piensa en un sistema de IA que hayas usado recientemente: un asistente de voz, un motor de recomendación, una herramienta de análisis de imágenes, un detector de *spam*. ¿Qué paradigma o combinación de paradigmas crees que lo sustenta? ¿Cuáles son los indicios

que te llevan a esa conclusión? ¿Y cuáles serían las consecuencias prácticas de esa elección para su comportamiento cuando encuentra situaciones que no conoce?

Modelos fundacionales y capacidades emergentes

Existe un consenso, aunque no unánime, de que los últimos cinco años representan un punto clave en la historia de la IA y no simplemente una aceleración de tendencias previas. La aparición de los modelos fundacionales constituye un cambio en la lógica misma de construcción de sistemas de IA, con implicaciones que alcanzan simultáneamente a todas las disciplinas que componen esta materia.

Importancia de los modelos fundacionales

Bommasani et al. (2021) acuñaron el término modelos fundacionales para designar sistemas entrenados a escala masiva sobre datos amplios y no estructurados, que pueden luego adaptarse a una amplia variedad de tareas específicas mediante ajuste fino o mediante instrucciones en contexto. La metáfora del fundamento es deliberada: estos modelos proveen una base de capacidades generales sobre la cual se construyen aplicaciones específicas, en lugar de ser diseñados desde cero para cada tarea.

Tres características distinguen a los modelos fundacionales de sus predecesores:

1. La escala. Se trata de cientos de miles de millones de parámetros entrenados con volúmenes de datos que habrían sido computacionalmente prohibitivos hace apenas una década. GPT-4 tiene aproximadamente más de un billón de parámetros, y Whisper fue entrenado con 680.000 horas de audio.
2. El preentrenamiento autosupervisado, que en lugar de requerir etiquetas humanas para cada ejemplo, lo cual resulta costoso a escala, los modelos aprenden a partir de objetivos como predecir la próxima palabra en un texto o reconstruir partes enmascaradas de una imagen.

3. La transferencia de capacidades, donde las representaciones aprendidas durante el preentrenamiento se transfieren a tareas específicas con muy pocos ejemplos de adaptación, un fenómeno conocido como aprendizaje con pocos ejemplos o sin ninguno.

Los modelos fundacionales cambian algo concreto en la práctica profesional, ya que es una arquitectura que se desarrolló para predecir palabras en un texto; puede reentrenarse para predecir la estructura tridimensional de una proteína.

Esa lógica se aplica en seguridad informática, donde modelos entrenados sobre repositorios de código identifican vulnerabilidades o sugieren parches, y en ciencia de datos, donde un analista puede hacerle preguntas a sus propios datos en lenguaje natural sin necesidad de traducirlas primero a una consulta técnica.

Wang et al. (2024) documentan algo similar en robótica, donde estos modelos funcionan como una capa de comprensión de alto nivel que toma una instrucción en lenguaje natural y la convierte en subobjetivos que el sistema de control puede ejecutar. Lo notable no es cada aplicación por separado, sino que todas comparten la misma base.

Multimodalidad y capacidades emergentes

Los modelos más avanzados no se limitan a un solo tipo de dato. Un mismo sistema puede recibir texto, imágenes y audio, procesarlos en conjunto y producir una respuesta que integra las tres fuentes. Un médico que describe síntomas verbalmente mientras muestra una imagen de laboratorio puede obtener una interpretación que considera ambas cosas al mismo tiempo; algo que antes requería herramientas separadas y un analista que las coordinara manualmente.

Lo que resulta más difícil de explicar es el fenómeno de las capacidades emergentes. A medida que estos modelos crecen en escala, aparecen habilidades que nadie diseñó ni anticipó. Un modelo que en cierto tamaño fallaba sistemáticamente al resolver problemas de razonamiento encadenado empieza a resolverlos bien al superar un umbral de parámetros, sin que haya cambiado nada en su arquitectura ni en el tipo de datos con que fue entrenado.

Bommasani et al. (2021) documentan varios casos de este tipo y señalan que el fenómeno no está completamente explicado. Hay quienes argumentan que estas capacidades son genuinas y quienes

sostienen que son un efecto de cómo se construyen las métricas de evaluación. Lo que no está en discusión es la consecuencia práctica, ya que estos sistemas pueden desarrollar comportamientos que sus propios creadores no predijeron, lo cual es tanto una oportunidad como una razón para evaluarlos con cuidado.

Oportunidades y riesgos

Sería un error concluir que los modelos fundacionales son omnipotentes. Tienen limitaciones reales, bien documentadas y profesionalmente relevantes, que todo profesional del área debe conocer.

El caso más conocido es el de las alucinaciones. Un modelo puede afirmar con total fluidez que un medicamento tiene cierta dosis recomendada, citar un estudio que no existe o describir el comportamiento de una proteína de manera incorrecta pero coherente. El problema no es que se equivoque, sino que lo hace con el mismo tono seguro con que acierta, lo cual dificulta detectar el error sin verificación independiente. Para alguien que usa estos sistemas en un contexto clínico o de seguridad, eso no es un detalle menor.

A esto se suman otras limitaciones. Los errores no son aleatorios, reflejan los sesgos presentes en los datos de entrenamiento y pueden reproducir y amplificar desigualdades de maneras difíciles de rastrear. Son vulnerables a instrucciones diseñadas para manipular su comportamiento de formas que sus creadores no anticiparon. Y no tienen acceso a información actualizada a menos que se conecten explícitamente con fuentes externas.

Bommasani et al. (2021) analizan estos riesgos en profundidad y agregan otros de carácter estructural, como la concentración del desarrollo de estos sistemas en pocas organizaciones y la dificultad práctica de auditar los modelos. Conocer estas limitaciones es una condición básica para usar estas herramientas con criterio profesional.

Aplicación al caso

Ahora que comprendiste los paradigmas, la historia y las características de los modelos fundacionales, puedes volver a analizar Whisper con un vocabulario mucho más preciso. Lo que al inicio parecía simplemente un sistema que transcribe audio revela una arquitectura con implicaciones conceptuales profundas.

Tabla 2. Características centrales de los cuatro paradigmas

Concepto de la lectura	¿Cómo se aplica al caso?
Paradigma subsimbólico	Whisper no tiene codificadas reglas fonológicas de ningún idioma. Aprendió representaciones estadísticas del habla a partir de 680.000 horas de pares audio-texto, siguiendo el paradigma subsimbólico puro: el conocimiento surge de los datos, no de la codificación explícita.
Modelo fundacional y transferencia	Whisper es un modelo fundacional: preentrenado a escala masiva y luego aplicable a tareas específicas (transcripción, traducción, identificación de idioma) sin reentrenamiento completo. Su arquitectura *Transformer* puede adaptarse a dominios específicos como transcripción médica o análisis forense de audio.
IA débil con capacidades emergentes	Whisper exhibe capacidades emergentes, ya que supera a sistemas especializados en idiomas poco representados, maneja ruido de fondo con robustez no programada explícitamente. Sin embargo, no deja de ser IA débil y falla en dialectos muy minoritarios porque no puede generalizar a tareas fuera de su dominio (no puede interpretar el significado de lo que transcribe).
Riesgos y sesgos del dato de entrenamiento	Sus errores no son aleatorios; son sistemáticamente peores en idiomas subrepresentados en internet. Esto ilustra cómo los sesgos del paradigma subsimbólico reflejan los sesgos de los datos, con consecuencias directas para la equidad de aplicaciones construidas sobre este modelo.

Fuente: elaboración propia.

Lo que hace a Whisper un caso especialmente instructivo para esta primera lectura es que concentra en un solo sistema la mayoría de las tensiones conceptuales que se han discutido: la potencia del paradigma subsimbólico y sus limitaciones de opacidad, el poder de los modelos fundacionales y su dependencia de datos que reflejan sesgos del mundo, las capacidades emergentes que nadie programó y los errores sistemáticos que nadie anticipó completamente.

Quedan abiertas preguntas más profundas que no tienen respuesta en los conceptos de esta lectura, sino que acompañarán todo el curso.

- ¿La capacidad de Whisper de transcribir 99 idiomas con precisión implica alguna forma de comprensión del habla, o es un sofisticado reconocimiento estadístico de patrones sin comprensión?
- ¿Puede confiarse en un sistema cuyos errores son sistemáticos pero difíciles de predecir de antemano?
- ¿Y cómo debería regularse el uso de este tipo de sistemas en contextos donde los errores tienen consecuencias legales, médicas o de seguridad?

Actividades de repaso de lecturas

ACTIVIDADES DE REPASO Y REFUERZO

PREGUNTAS VERDADERO/FALSO

El enfoque de actuar racionalmente o del agente racional fue descartado en la IA moderna porque exige que el sistema replique con exactitud los procesos cognitivos y biológicos del cerebro humano.

Es verdadero, porque la IA solo se considera exitosa si logra imitar las emociones y la intuición humana producto de la evolución.

Es falso, porque el enfoque del agente racional no busca imitar el pensamiento humano, sino seleccionar la acción que maximice el rendimiento esperado a partir de lo que percibe del entorno.

Referencias

Bommasani, R., Hudson, D. A., Aditi, E., Altman, R., Arora, S., Koreeda, Y., y Liang, P. (2021). *On the opportunities and risks of foundation models*. Center for Research on Foundation Models, Stanford University. https://arxiv.org/abs/2108.07258

Krizhevsky, A., Sutskever, I., y Hinton, G. E. (2017). ImageNet large scale visual recognition challenge. *Communications of the ACM*, 60(6), 84–90. https://doi.org/10.1145/3065386

Kambhampati, S. (2020). Symbols and sub-symbolism: The hybrid AI debate. *AI Magazine*, 41(1), 5–7. https://doi.org/10.1609/aimag.v41i1.5219

Maureira Cid, F. (2017). *¿Qué es la inteligencia?* (1a ed.). Bubok.

Murphy, K. P. (2022). *Probabilistic machine learning: An introduction*. MIT Press. https://probml.github.io/pml-book/book1.html

Raschka, S., y Mirjalili, V. (2017). *Python machine learning: Machine learning and deep learning with Python, scikit-learn, and TensorFlow* (2a ed.). Packt Publishing.

Russell, S., y Norvig, P. (2016). *Artificial intelligence: A modern approach* (3a ed.). Pearson.

Turing, A. M. (1950). Computing Machinery and Intelligence. *Mind*, 59(236), 433–460.