Agentes inteligentes y autonomía

Introducción

Imagina por un momento que debes resolver el siguiente problema: detectar, en tiempo real, si un paquete de red que acaba de llegar a un servidor corporativo es parte de un ataque coordinado o tráfico legítimo. No hay tiempo para llamar a un analista; la decisión la debes tomar rápidamente. Algo parecido ocurre cuando un robot en un almacén tiene que encontrar el camino entre operarios que se mueven, cajas que aparecen y rutas que cambian cada hora.

Los dos casos exigen lo mismo. Un sistema que perciba lo que está pasando, procese información compleja y actúe por su cuenta, sin que nadie le diga qué hacer en cada momento. Eso es, en términos técnicos, lo que la IA llama agentes inteligentes, y entender cómo funcionan es el objetivo de esta lectura.

Russell y Norvig (2016) plantean que casi cualquier sistema de IA puede describirse como un agente que observa su entorno y actúa sobre él, y que eso lo convierte en el concepto más unificador de toda la disciplina. Los enfoques clásicos se concentraban en representar conocimiento de forma aislada, como si pensar fuera suficiente sin importar qué pasa afuera. El paradigma del agente cambia eso porque lo que importa es la interacción continua entre el sistema y su entorno, y esa interacción es exactamente lo que las aplicaciones modernas exigen.

Para alguien en seguridad informática, esa diferencia puede ser la que separa detectar un ataque en segundos, de descubrirlo horas después. Para alguien que gestiona operaciones logísticas, la que permite a un robot adaptarse a un almacén en movimiento sin que nadie lo esté dirigiendo. En robótica, en desarrollo de productos, la lógica es la misma. Los agentes no solo procesan información, actúan en el mundo.

En los últimos años, los modelos de lenguaje de gran escala abrieron posibilidades que antes eran difíciles de imaginar, y los agentes de nueva generación pueden razonar, planificar y usar herramientas de formas que hace una década parecían ciencia ficción. Eso no dejó atrás los fundamentos clásicos, los puso en perspectiva.

Por eso, este recorrido empieza desde qué distingue la automatización de la autonomía, cómo está construido un agente por dentro, en qué tipos de entornos opera, qué formas puede tomar y cómo todo eso se conecta con los sistemas más modernos.

Caso: Amazon Robotics

En 2012, Amazon adquirió Kiva Systems por 775 millones de dólares, la compra más grande que había realizado hasta ese momento en el campo de la robótica. La premisa era que, en lugar de que los operarios caminaran kilómetros por día buscando productos entre estanterías, las estanterías se movieran solas hasta los operarios. Lo que no era simple era lo que eso implicaba por dentro.

Los robots Kiva, rebautizados Amazon Robotics, debían operar en almacenes enormes, coordinarse con cientos de otros robots en movimiento simultáneo, evitar colisiones, priorizar pedidos según urgencia y adaptarse en tiempo real a un entorno que cambiaba constantemente. No había rutas fijas ni secuencias predefinidas que pudieran cubrir esa variabilidad. El sistema tenía que percibir lo que estaba pasando, razonar sobre ello y actuar, todo en cuestión de segundos y sin intervención humana en cada decisión.

Lo que hacía esto relevante no era la escala de la operación y la arquitectura que la hacía posible. Cada robot percibía su entorno a través de sensores y cámaras, mantenía una representación interna de su posición y del estado del almacén, recibía objetivos del sistema central y planificaba la secuencia de acciones para alcanzarlos. Cuando aparecía un obstáculo no previsto, no se detenía a esperar instrucciones, sino que recalculaba. Cuando las condiciones del almacén cambiaban, el sistema ajustaba la asignación de tareas entre robots en tiempo real.

Para un científico de datos, este caso plantea preguntas concretas sobre diseño de sistemas:

- ¿Cómo se coordina el comportamiento de cientos de agentes que comparten el mismo entorno físico?
- ¿Cómo se balancea la velocidad de respuesta reactiva con la calidad de la planificación deliberativa?
- ¿Qué tipo de representación interna necesita un agente para operar eficientemente

en un entorno dinámico y parcialmente impredecible?

Ninguna de esas preguntas tiene respuesta sin entender qué tipo de agente está operando y en qué clase de entorno lo hace.

El caso Amazon Robotics es una puerta de entrada a las cuestiones centrales que esta lectura busca responder: qué distingue la automatización de la autonomía, cómo está construido un agente por dentro, qué propiedades del entorno determinan qué arquitectura es viable y qué formas puede tomar un agente según la complejidad del problema que enfrenta.

Reflexiona



Haz clic para girar la tarjeta

(Información del reverso a continuación)

Antes de continuar, considera lo siguiente: los robots de Amazon perciben su entorno, replantean rutas ante obstáculos y coordinan sus movimientos con cientos de otros robots sin intervención humana en cada decisión. ¿Eso los hace verdaderamente autónomos? ¿Qué diferencia habría entre este sistema y un robot que simplemente sigue una ruta fija programada de antemano?

Desde la automatización a la autonomía

Existe una distinción conceptual que vale la pena establecer antes de avanzar, porque en la práctica se confunden con frecuencia: la diferencia entre un sistema automático y un agente

autónomo. Ambos operan sin intervención humana continua, pero lo hacen de maneras fundamentalmente distintas.

Un sistema automático ejecuta una secuencia de acciones que alguien diseñó de antemano para condiciones previstas. El piloto automático de un avión es el ejemplo más claro. Mantiene altitud, rumbo y velocidad haciendo correcciones constantes a partir de sensores, pero esas correcciones siguen un algoritmo que ingenieros humanos escribieron, y ese algoritmo no cambia si aparece algo que nadie anticipó. Ante una tormenta sin precedentes o un fallo múltiple de instrumentos, el piloto automático no improvisa. Simplemente no tiene herramientas para hacerlo.

El sistema no genera nuevas estrategias; aplica las que tiene codificadas. Si aparece una situación completamente fuera de los parámetros previstos, por ejemplo, un sistema de tormentas sin precedentes o un fallo múltiple de instrumentos, el piloto automático simplemente no sabe qué hacer.

> Un sistema autónomo, en cambio, puede generar comportamientos nuevos ante situaciones no anticipadas. Russell y Norvig (2016) señalan que la autonomía implica la capacidad de un agente de basar sus acciones en su propia experiencia y razonamiento, en lugar de depender enteramente del conocimiento incorporado por su diseñador. Esta distinción no es meramente filosófica: tiene consecuencias de diseño inmediatas.

Figura 1. Automático vs. autónomo



Fuente: elaboración propia.

Observa algunos ejemplos:

- Un robot móvil diseñado para operar en entornos de manufactura puede ser simplemente automático si sigue rutas fijas entre puntos predefinidos, o genuinamente autónomo si es capaz de replantear su ruta cuando detecta un obstáculo no previsto, estimar la urgencia relativa de distintas tareas y adaptar su comportamiento a cambios en el layout del almacén.

- En ciberseguridad, un sistema SOC (Security Operations Center, en español Centro de Operaciones de Seguridad) inteligente que solo ejecuta reglas predefinidas es automático; uno que analiza patrones nuevos de comportamiento, correlaciona eventos de múltiples fuentes y genera hipótesis sobre amenazas emergentes se acerca mucho más a la autonomía.

- Un agente conversacional como un asistente virtual médico que solo recupera respuestas de una base de conocimiento fija es automático; uno que reformula sus preguntas según las respuestas del paciente, reconoce ambigüedad y adapta su estrategia de indagación es autónomo.

La diferencia fundamental está en tres capacidades que los sistemas automáticos generalmente no poseen: adaptación al entorno, toma de decisiones dinámica y retroalimentación auténtica.

Adaptación al entorno

La adaptación implica que el comportamiento del sistema cambia en función del estado del entorno, no solo de sus parámetros internos. Un termostato simple reacciona a la temperatura; un sistema de climatización inteligente aprende los patrones de uso del edificio y anticipa las necesidades de temperatura según el día de la semana, la ocupación y la temporada. La diferencia es que el primero reacciona, el segundo anticipa y se adapta.

En bioinformática, esta distinción se vuelve muy relevante. Un análisis genómico que procesa siempre las mismas etapas con los mismos parámetros es automático. Un agente de análisis genómico que ajusta sus umbrales de calidad según la distribución específica de los datos de entrada, decide qué variantes requieren validación adicional y prioriza el reporte según su relevancia clínica potencial; está adaptándose al entorno de datos que enfrenta.

Toma de decisiones dinámica y retroalimentación

La toma de decisiones dinámica supone que el agente no sigue un árbol de decisión fijo, sino que evalúa el estado actual y las posibles acciones en función de criterios que pueden incluir objetivos múltiples, incertidumbre y preferencias ponderadas. Murphy (2022) argumenta que la capacidad de razonar bajo incertidumbre, asignando probabilidades a estados del mundo y acciones posibles, es lo que distingue a los agentes que genuinamente deliberan de los que simplemente reaccionan.

La retroalimentación, por su parte, cierra el ciclo. Un agente que actúa, observa el resultado de su acción y ajusta su modelo del mundo en consecuencia está implementando un proceso de aprendizaje continuo que ningún sistema puramente automático puede replicar. Esta capacidad de actualizar el comportamiento basándose en la experiencia acumulada es uno de los rasgos típicos en los agentes basados en LLM (Large Language Model System) (Wang, Ma, Feng, Zhang, Yang, Zhang, Chen, Tang, Chen, Lin, Zhao, Wei y Wen, 2024).

Comportamiento reactivo vs. deliberativo

Dentro del espectro de los agentes autónomos, convive una tensión clásica entre dos modalidades de operación. El comportamiento reactivo produce respuestas rápidas a los estímulos del entorno sin recurrir a representaciones complejas del mundo o planificación a largo plazo: el sistema percibe y actúa casi de forma directa, siguiendo reglas del tipo 'si detecto X, hago Y'. No hay modelo interno, no hay anticipación, no hay evaluación de consecuencias futuras. Su ventaja es la velocidad; su limitación es que no puede razonar sobre lo que no está directamente visible en el momento actual.

El comportamiento deliberativo, en contraste, implica construir modelos internos del entorno, razonar sobre estados futuros posibles y seleccionar acciones en función de esa anticipación. Un agente deliberativo reacciona a lo que percibe en el momento y se pregunta qué va a pasar si actúa de cierta manera, evalúa alternativas y elige la que mejor se alinea con sus objetivos. Ese proceso de razonamiento tiene un costo: requiere tiempo y recursos computacionales que no siempre están disponibles.

Ninguna de las dos modalidades es superior en términos absolutos. Los sistemas reactivos tienen latencias mucho menores, importante en aplicaciones de tiempo real como la respuesta a incidentes de seguridad o el control de robots, pero son frágiles ante situaciones no previstas. Los sistemas deliberativos pueden encontrar soluciones óptimas a problemas complejos, pero su costo computacional puede hacerlos inapropiados para dominios donde el tiempo de respuesta es crítico.

Las arquitecturas híbridas, que combinan una capa reactiva rápida con una capa deliberativa más lenta, representan el diseño dominante en sistemas de IA avanzada actuales. Un robot de almacén que frena de inmediato ante un obstáculo (reactivo) pero planifica su ruta óptima considerando decenas de variables antes de moverse (deliberativo) es un ejemplo concreto de cómo ambas capas coexisten y se complementan (Russell & Norvig, 2016).

Reflexiona



Haz clic para girar la tarjeta

(Información del reverso a continuación)

Piensa en un sistema que conoces o que forma parte de tu área de especialización: ¿es automático o autónomo? Si es automático, ¿qué tendría que cambiar en su diseño para que cruzara esa frontera?, ¿qué aspectos de su entorno harían esa transición más difícil?

Arquitectura de un agente inteligente

Comprender cómo funciona un agente inteligente por dentro es clave para poder clasificarlos, diseñarlos o evaluarlos. Russell y Norvig (2016) proponen una arquitectura conceptual que, con variaciones, aplica a prácticamente cualquier agente de IA: desde un robot de exploración espacial hasta un sistema de detección de fraude bancario. A continuación, podrás analizar sus componentes.

Sensores y percepción

Todo agente comienza con la percepción, que es la capacidad de recibir información del entorno. Los sensores son los mecanismos físicos o lógicos que hacen posible esa recepción. Un robot de servicio combina sensores de distancia (LIDAR), cámaras, micrófonos y sensores de presión en sus extremidades. Un agente de seguridad informática sensa el entorno a través de sniffers o logs de sistema.

Lo importante es que percibir no es simplemente leer datos crudos, sino interpretarlos y estructurarlos para que sean útiles al razonamiento posterior. Un robot que detecta 0,3 metros de distancia frente a él no almacena ese número y sigue adelante; lo traduce en 'hay un obstáculo cercano'. Un sistema de seguridad que recibe 10.000 paquetes por segundo no los acumula, sino que identifica patrones significativos en ese flujo. La percepción, en este sentido, ya es una forma de procesamiento, y su calidad determina en gran medida el desempeño del agente.

Representación interna del estado

Una vez que el agente percibe el entorno, necesita alguna forma de organizar lo que sabe sobre él. Esa representación interna puede ser tan simple como el estado actual de un semáforo o tan compleja como el modelo tridimensional que un robot autónomo construye en tiempo real mientras navega.

Russell y Norvig (2016) proponen una taxonomía basada en la complejidad de la arquitectura interna, que determina directamente qué completa es esa imagen:

- En el extremo más básico están los agentes que solo reaccionan a lo que perciben en este momento, sin recordar nada ni anticipar nada.
- En el extremo opuesto, los más sofisticados pueden modificar su propio funcionamiento a partir de la experiencia acumulada.

La arquitectura interna, en este sentido, no es un componente aislado, sino lo que define qué tipo de agente se tiene y qué tan sofisticado puede ser su comportamiento.

Piensa en un sistema que predice el abandono de clientes. En cada momento, el agente recibe datos como: el cliente acaba de abrir la app, navegó tres pantallas y cerró sin comprar. Eso es lo que está viendo ahora, es decir, su percepción actual, y no alcanza para tomar decisiones. Lo que realmente informa la decisión es lo que el agente recuerda: que ese mismo cliente lleva dos semanas con sesiones cada vez más cortas, que solía comprar los jueves y hace un mes que no lo hace, que su ticket promedio bajó un 40%. Eso es el modelo del mundo: son features construidas sobre ventanas temporales que comprimen el comportamiento pasado en algo útil. Y cuando el agente combina todo eso para estimar que hay un 78% de probabilidad de que ese cliente se vaya en los próximos 15 días, está proyectando con un pronóstico un estado futuro.

En seguridad informática, la lógica es la misma, pero el costo de equivocarse es diferente. Un agente de detección de intrusiones no puede trabajar solo con lo que ve en este paquete, sino que necesita saber quién lo mandó, desde dónde, a qué hora, si ese host se comportó raro la semana pasada, si ese usuario nunca había accedido a ese recurso.

Todo eso forma su representación interna: un grafo de conexiones entre hosts, historiales de comportamiento por usuario, estimaciones de riesgo por nodo. El problema de diseño que aparece aquí es concreto, ya que cuanto más rica es esa representación, más tarda el agente en razonar. Y en seguridad, la latencia tiene un precio.

Razonamiento y toma de decisiones

Con una representación del estado disponible, el agente puede razonar; es decir, evaluar qué acciones son posibles, cuáles lo acercan a sus objetivos y cuáles son preferibles dados los recursos disponibles y la incertidumbre presente. Este componente es donde reside, en gran medida, la inteligencia del agente.

Russell y Norvig (2016) describen el razonamiento como la función de agente que mapea historias de percepciones a acciones. Lo que importa entender en este punto, antes de profundizar en los tipos de agentes, es una limitación estructural que suele pasarse por alto. El agente nunca razona sobre el entorno real directamente, razona sobre su representación interna de ese entorno. Todo lo que esa representación no capture, el agente lo ignora, aunque exista.

Piensa en el sistema de predicción de abandono de clientes. Si el modelo no tiene registrado que ese usuario abrió un ticket de soporte sin resolver hace tres días, ese dato no existe para el agente. Su razonamiento va a ser tan bueno como lo que su representación interna contiene.

Lo mismo pasa en un agente de detección de intrusiones. Si un ataque se distribuye en patrones que el estado interno no está diseñado para capturar, el agente no va a razonar sobre esa amenaza y simplemente no la va a ver.

La toma de decisiones es el siguiente paso. Una vez que el razonamiento identifica qué acciones son posibles, alguien tiene que elegir una. Cuando hay una opción claramente superior, la elección es simple, pero el problema aparece cuando hay varias opciones válidas. El sistema de predicción de abandono puede elegir entre alertar a todo cliente con más del 60% de probabilidad de irse (capturando más casos, pero generando más intervenciones innecesarias) o subir ese umbral al 80% y ser más preciso, pero perder algunos clientes en riesgo. El agente de detección de intrusiones enfrenta una tensión similar: puede bloquear tráfico sospechoso de forma agresiva, reduce el riesgo, pero puede cortar conexiones legítimas.

En los agentes más simples, esos criterios de elección son reglas fijas. En los más sofisticados, son funciones de utilidad que ponderan múltiples factores y pueden ajustarse según el contexto.

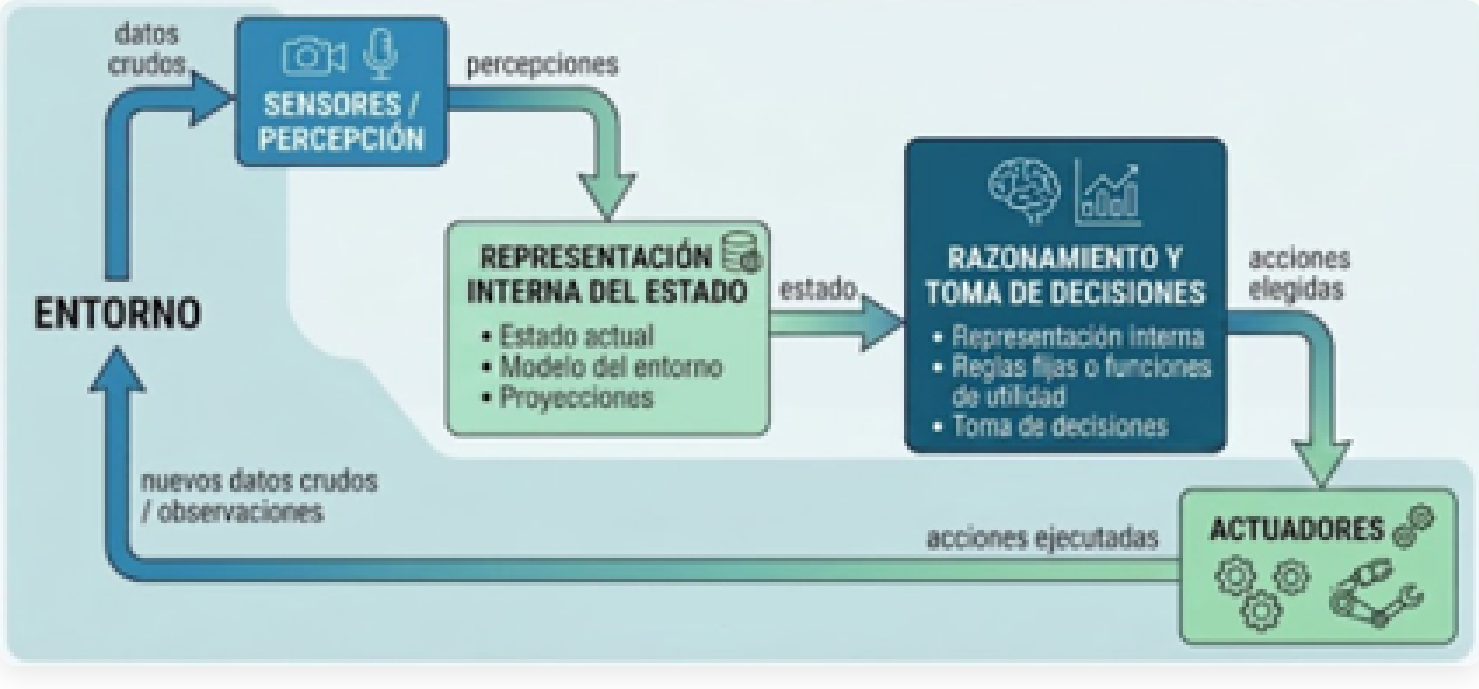
Actuadores y el ciclo percepción-procesamiento-acción

Los actuadores son los mecanismos mediante los cuales el agente modifica el entorno; es el componente que cierra el ciclo entre razonamiento y acción. Sin actuadores, el agente puede percibir y razonar, pero no tiene forma de intervenir en el entorno que está observando.

El ciclo completo percepción-procesamiento-acción no es una secuencia lineal que se agota en una iteración, sino que es continua. El agente actúa, esa acción modifica el entorno, el entorno modificado genera nuevas percepciones y el ciclo se reinicia. Es exactamente esa naturaleza iterativa la que le da al agente su capacidad de adaptarse: cada vuelta es una oportunidad para actualizar lo que sabe y ajustar lo que hace.

Piensa en el sistema de predicción de abandono. El agente detecta riesgo alto, dispara una campaña de retención, y eso modifica el comportamiento del cliente. Esa modificación vuelve como nueva percepción en el siguiente ciclo: el cliente respondió, ignoró la oferta o canceló de todas formas. Cada una de esas respuestas actualiza el estado interno y ajusta las decisiones futuras. En el agente de detección de intrusiones ocurre lo mismo, ya que bloquear un host modifica el entorno de red, y esa modificación puede revelar nuevos patrones de comportamiento que el agente no había visto antes.

Figura 2. Arquitectura de un agente inteligente



Fuente: elaboración propia.

Tipos de entorno

Un error conceptual en el diseño de sistemas de IA es concebir el agente de forma abstracta, sin considerar las propiedades del entorno en el que va a operar. Sin embargo, esas propiedades determinan de forma casi directa qué arquitectura de agente es viable, qué tipo de representación interna es necesaria y qué nivel de razonamiento tiene sentido implementar.

Russell y Norvig (2016) proponen una taxonomía de propiedades de entorno que sigue siendo la referencia estándar en el campo. A continuación, se analiza cada dimensión con ejemplos que recorren múltiples dominios.

Observable y parcialmente observable

Un entorno es completamente observable cuando el agente puede acceder en cada momento a toda la información relevante sobre el estado del mundo. En la práctica, los entornos completamente observables son la excepción, no la regla.

Un juego de ajedrez es completamente observable, ya que ambos jugadores ven el tablero completo en todo momento. Un juego de póker es parcialmente observable porque cada jugador conoce sus propias cartas, pero no las de los demás.

La definición es fundamental para el diseño. En entornos completamente observables, el agente no necesita mantener historia ni hacer inferencias sobre estados ocultos, dado que puede tomar decisiones basándose únicamente en el estado actual. En entornos parcialmente observables, el agente necesita construir y mantener una estimación del estado oculto y actualizar esa estimación a medida que llega nueva información (Murphy, 2022).

Para los especialistas en seguridad informática, prácticamente todos los entornos de interés son parcialmente observables. Un atacante deliberadamente oculta su actividad; los logs que el agente defensivo puede observar son una muestra parcial y potencialmente manipulada del estado real de la red. Diseñar agentes que funcionen bien bajo esta opacidad informacional es uno de los desafíos centrales de la ciberseguridad automatizada.

En contraste, un sistema de control de semáforos en una intersección equipada con sensores en cada carril es completamente observable. El agente conoce en todo momento cuántos vehículos hay en cada fila, a qué velocidad avanzan y cuánto tiempo lleva cada luz activa. No hay información oculta relevante; el agente puede tomar decisiones óptimas mirando únicamente el estado actual. Este tipo de entorno es inusual precisamente porque fue diseñado para serlo, dado que los ingenieros instalaron los sensores necesarios para eliminar la incertidumbre.

Determinístico vs. estocástico

En un entorno determinístico, cada acción del agente produce exactamente un resultado previsible dado el estado actual. El movimiento de una pieza de ajedrez es determinístico porque, dado el estado del tablero, se puede calcular con precisión adónde va cada pieza y cuál será el estado resultante. En entornos estocásticos, en cambio, el resultado de una acción tiene un componente aleatorio que el agente no puede controlar completamente.

La mayoría de los entornos del mundo real son estocásticos:

- Los datos de tráfico vehicular contienen ruido estadístico.
- Los resultados de los análisis clínicos presentan variabilidad biológica.
- Las respuestas de los servidores en una red están afectadas por cargas variables.
- El comportamiento de un robot en un entorno físico está sujeto a imprecisiones en los actuadores y perturbaciones externas.

Murphy (2022) dedica una parte de su libro a los métodos probabilísticos que permiten a los agentes razonar y actuar en presencia de esta estocasticidad.

Un robot de servicio que opera en un entorno con personas debe tratar las posiciones y trayectorias de los humanos como variables estocásticas. Predecir con certeza adónde se desplazará una persona en los próximos dos segundos es imposible; el enfoque correcto consiste en estimar una distribución de probabilidad sobre sus posibles trayectorias y actuar de forma que resulte segura para todas las trayectorias probables. La diferencia tiene consecuencias directas en la seguridad operacional del sistema.

Episódico vs. secuencial

Esta dimensión determina si las acciones del agente en un momento dado afectan o no a sus opciones en el futuro. En entornos episódicos, cada interacción es independiente y la decisión tomada en un episodio no modifica las opciones disponibles en el siguiente. En entornos secuenciales, las decisiones actuales tienen consecuencias a largo plazo que el agente debe anticipar.

Clasificar el spam en el correo electrónico es esencialmente episódico, porque la decisión sobre un correo particular no afecta cómo se clasificarán los correos siguientes (al menos en el corto plazo). Jugar una partida de ajedrez es claramente secuencial porque cada movimiento cambia el estado del tablero y las posibilidades futuras. La mayoría de las aplicaciones de agentes en dominios reales son al menos parcialmente secuenciales.

En ciencia de datos, un agente de recomendación de contenido opera en un entorno secuencial. La recomendación que hace ahora afecta al historial del usuario, que a su vez afecta a las recomendaciones futuras. Ignorar esta secuencialidad puede llevar a patrones indeseables como el filtro burbuja o la sobreexposición a ciertos tipos de contenido. Los algoritmos de aprendizaje por refuerzo son, en gran medida, métodos para aprender a actuar bien en entornos secuenciales donde los efectos de las acciones se despliegan en el tiempo.

En seguridad informática, los agentes de respuesta a incidentes operan en entornos secuenciales. La decisión de bloquear un puerto o aislar un segmento de red hoy modifica la superficie de ataque disponible mañana, lo que a su vez determina qué vectores de intrusión seguirán siendo viables la semana siguiente.

Un atacante sofisticado explota precisamente esta secuencialidad, ya que sus acciones tempranas no buscan necesariamente un efecto inmediato, sino posicionarse favorablemente para etapas posteriores. Un agente defensivo que trate cada alerta como un episodio independiente, sin considerar cómo sus respuestas previas han reconfigurado el entorno, será superado por adversarios que sí planifican en horizonte largo.

Dinámico vs. estático

Un entorno estático no cambia mientras el agente está deliberando. Un entorno dinámico cambia independientemente de las acciones del agente y, en algunos casos, el solo paso del tiempo constituye un cambio de estado relevante. Los entornos dinámicos son particularmente desafiantes porque introducen una presión temporal sobre el razonamiento del agente, ya que una respuesta tardía puede ser peor que ninguna respuesta.

El entorno de ciberseguridad es dinámico por definición. Un atacante adapta sus tácticas en respuesta a las defensas; el tráfico de red varía continuamente; las vulnerabilidades disponibles cambian a medida que aparecen parches. Un agente de respuesta a incidentes que tarda demasiado en decidir puede encontrarse con que el atacante ya ha avanzado varias etapas más en su cadena de ataque. Esta presión temporal demanda velocidad de procesamiento y arquitecturas que permitan tomar decisiones razonablemente buenas con información incompleta dentro de ventanas de tiempo muy estrechas.

En contraste, el análisis de datos históricos es típicamente estático desde la perspectiva del agente analítico: los datos no cambian mientras el científico de datos los explora. Esto simplifica enormemente el diseño de los agentes de análisis exploratorio, que pueden tomarse el tiempo necesario para producir representaciones y modelos de alta calidad sin preocuparse por la dinámica del entorno durante el proceso.

Tipos de agentes inteligentes

La taxonomía de tipos de agentes que Russell y Norvig (2016) proponen ha demostrado ser duradera. No porque el campo haya dejado de evolucionar, sino porque esta clasificación captura variaciones fundamentales en la forma en que los agentes representan el entorno y deliberan sobre él.

Figura 3. Taxonomía de agentes inteligentes



Fuente: elaboración propia.

Agentes reactivos simples

El agente reactivo simple percibe el estado actual del entorno y selecciona una acción basada exclusivamente en él, sin acceso a ningún historial previo ni capacidad de proyectar consecuencias futuras. Su lógica interna se reduce a un conjunto de reglas condición-acción: si el entorno presenta el estado X, ejecuta la acción Y. No hay memoria, no hay anticipación, no hay deliberación.

Esto lo hace muy rápido y predecible, lo cual en ciertos contextos es exactamente lo que se necesita. Pero, como señala Murphy (2022), en cuanto el entorno requiere que la decisión correcta dependa de algo que no está directamente visible en el momento actual, este tipo de agente se queda sin herramientas. No puede razonar sobre lo que pasó antes ni sobre lo que podría pasar después. En la práctica, aparece como componente dentro de sistemas más grandes, cubriendo tareas donde la reacción inmediata es suficiente y la complejidad deliberativa sería un costo innecesario.

Por ejemplo, puede analizarse una máquina dispensadora inteligente en una fábrica que entrega materiales a los operarios. Cada vez que detecta que el nivel de un insumo bajó de cierto umbral, dispara una orden de reposición. No sabe si hay una parada de planta programada para mañana, no recuerda que la semana pasada también pidió lo mismo y llegó tarde, no proyecta; solo

reacciona. Para ese caso concreto funciona bien, pero si la fábrica empieza a tener picos de demanda irregulares, ese agente va a seguir reaccionando igual aunque la situación haya cambiado por completo.

Un sensor de colisión en un brazo robótico de manufactura funciona de la misma manera. Si detecta resistencia inesperada, detiene el movimiento. No analiza por qué apareció esa resistencia, no consulta el historial de operaciones anteriores, no evalúa si tiene sentido detenerse en ese momento del ciclo. Simplemente aplica la regla. Para esa función específica, que es proteger al operario y al equipo, esa reacción inmediata es exactamente lo que se necesita. El problema aparece si se espera que ese mismo agente tome decisiones más complejas sobre cómo continuar la tarea.

Figura 4. Agente reactivo simple



Fuente: elaboración propia.

Agentes basados en modelos

El agente basado en modelos da un paso conceptual importante respecto al reactivo. Mantiene un estado interno que representa aspectos del entorno que no son directamente observables en el momento actual. Ese estado interno es el modelo que le da nombre al tipo de agente, y es lo que le permite razonar más allá de lo que tiene frente a él.

Ese modelo se construye y actualiza combinando dos tipos de conocimiento:

- El primero describe cómo evoluciona el entorno con el tiempo, independientemente de lo que haga el agente.

- El segundo describe cómo las propias acciones del agente modifican ese entorno.

Esta combinación le permite al agente mantener una representación coherente del mundo incluso cuando la percepción directa es parcial o temporalmente ausente. El agente no espera volver a ver algo para seguir razonando sobre ello. Murphy (2022) refuerza este punto señalando que los entornos parcialmente observables son la norma en aplicaciones reales, lo que convierte esta capacidad en un requisito frecuente.

Figura 5. Agentes basados en modelos



Fuente: elaboración propia.

> Imagina que analizas el comportamiento de usuarios en una plataforma de streaming. No todos los usuarios interactúan con la plataforma todos los días, así que en un momento dado hay muchos de los que no existe señal reciente.
>
> Un agente basado en modelos no espera a que el usuario vuelva a aparecer para saber algo de él. Mantiene una representación interna de su perfil, actualizada con lo que sabe de sus patrones históricos y de cómo usuarios similares se comportaron en situaciones parecidas. Con eso puede seguir tomando decisiones sobre qué mostrarle cuando vuelva, sin necesitar que esté activo en este momento.

Un sistema de detección de amenazas que solo analiza el paquete de red que acaba de llegar es reactivo. Uno basado en modelos mantiene una representación del estado probable de cada conexión activa: cuánto tiempo lleva abierta, qué volumen de datos transfirió, si el patrón es consistente con el comportamiento histórico de esa IP.

Cuando llega un paquete que en aislamiento parece inofensivo, el agente puede evaluarlo contra ese modelo acumulado y detectar que forma parte de un patrón de reconocimiento lento que ninguna regla individual hubiera capturado.

Los sistemas expertos que surgieron en las décadas de 1970 y 1980 son un ejemplo histórico de esta categoría. Mantenían un modelo interno del dominio, por ejemplo, el estado probable de una enfermedad a partir de síntomas, pero ese modelo no se construía desde la experiencia, sino desde conocimiento codificado manualmente por especialistas. El agente podía razonar sobre lo que no era directamente observable, pero dentro de los límites de lo que alguien había escrito en su base de conocimiento.

Agentes orientados a objetivos

Tener un modelo del entorno es necesario, pero no suficiente, para que un agente pueda actuar de forma inteligente en situaciones complejas. El modelo le dice cómo es el entorno y cómo cambia, pero no le dice hacia dónde ir. El agente orientado a objetivos incorpora esa pieza que falta, una descripción explícita de los estados que desea alcanzar. Con esa descripción puede planificar, es

decir, buscar en el espacio de acciones posibles una secuencia que lo lleve desde el estado actual al estado deseado.

La separación entre el conocimiento sobre el entorno y la especificación del objetivo tiene una consecuencia de diseño. El mismo agente puede perseguir objetivos distintos sin necesidad de rediseñar el razonamiento subyacente. Basta con cambiar la descripción del objetivo. Esto le da una flexibilidad que los tipos anteriores no tienen.

Murphy (2022) señala que algoritmos como A* o primero el mejor son implementaciones concretas de esta capacidad deliberativa, y que la elección entre ellos depende de la complejidad del espacio de estados, la calidad de la heurística disponible y los requisitos temporales del dominio.

Supón que estás desarrollando un sistema de navegación para un dron que tiene que hacer relevamientos en zonas de difícil acceso. El dron conoce el mapa del área, sabe dónde está y tiene un objetivo claro, que es llegar al punto de relevamiento evitando obstáculos y minimizando el consumo de batería. Lo interesante es que si mañana necesitas que haga el mismo recorrido, pero priorizando velocidad porque hay condiciones climáticas cambiantes, no es necesario reescribir cómo razona, sino solo cambiar el objetivo; el razonamiento es el mismo.

Figura 6. Agentes orientados a objetivos



Fuente: elaboración propia.

Un agente de optimización de cadena de suministro funciona de la misma manera. Conoce el estado actual del inventario, los tiempos de entrega de cada proveedor, los costos de transporte y la demanda proyectada. El objetivo es minimizar el costo total garantizando que no haya quiebres de stock. Si las condiciones del negocio cambian y el nuevo objetivo es reducir el tiempo de entrega al cliente, aunque eso implique mayor costo logístico, el agente puede reorientar su planificación sin que nadie tenga que reescribir la lógica de cómo busca soluciones.

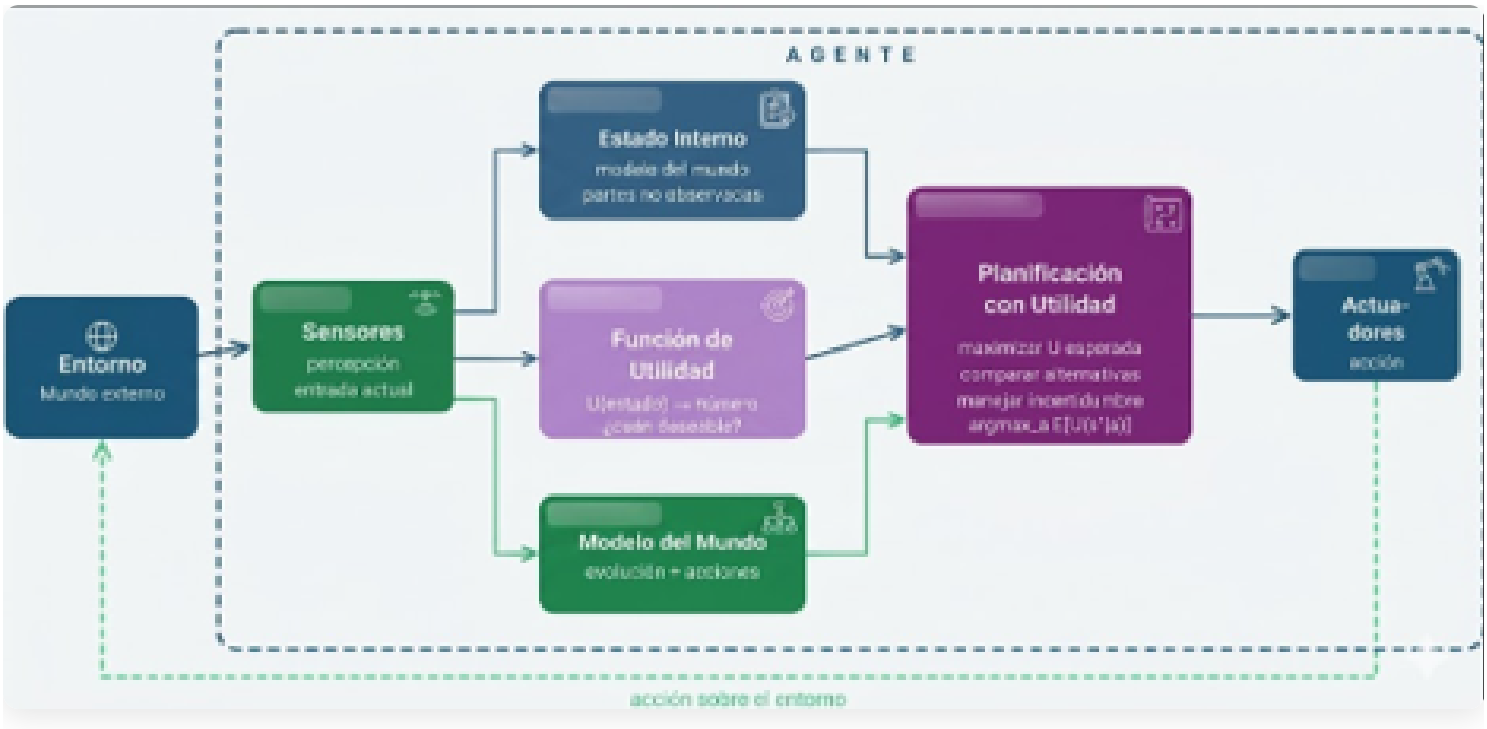
Algunos sistemas expertos con motor de inferencia orientado a metas entran también en esta categoría. Los que usaban encadenamiento hacia atrás no solo mantenían un modelo del dominio, sino que razonaban explícitamente hacia un objetivo. Por ejemplo, confirmar o descartar un diagnóstico, evaluando qué información faltaba para alcanzarlo. Eso los distingue del agente basado en modelos puro y los acerca a la lógica de planificación orientada a objetivos.

Agentes basados en utilidad

Los objetivos tienen una naturaleza binaria, es decir, que se alcanzan o no se alcanzan. En muchos casos eso es suficiente, pero en los problemas más interesantes del mundo real esa simplicidad no es posible. A veces hay varias formas de alcanzar un objetivo y algunas son claramente mejores que otras. A veces hay múltiples objetivos que tiran en direcciones opuestas. A veces ninguna acción disponible logra el objetivo plenamente y hay que elegir cuál es la que conviene.

El agente basado en utilidad aborda esa complejidad reemplazando la noción binaria de objetivo por una función de utilidad, que es una representación numérica de cuán deseable es cada estado posible del mundo. Con esa función, el agente puede comparar estados que no son directamente comparables con criterios de sí o no, y seleccionar la acción que maximiza la utilidad esperada. Murphy (2022) formaliza este concepto en el marco de la teoría de la decisión bayesiana, donde la utilidad esperada integra tanto la preferencia por los estados como la incertidumbre sobre cuál de ellos va a resultar de cada acción.

Figura 7. Agente basado en utilidad



Fuente: elaboración propia.

> Cuando un sistema de respuesta a incidentes tiene que decidir si bloquear o no un flujo de tráfico sospechoso, la decisión depende de varios factores. Si se bloquea y era tráfico legítimo, se produce un corte de servicio. Si no se bloquea y era un ataque, se deja pasar algo que no debía hacerlo.
>
> Un agente basado en utilidad pondera estos dos tipos de error según qué tan crítico es el sistema que está protegiendo. En un sistema bancario, la función de utilidad penaliza mucho más el falso negativo. En una plataforma de contenido, quizás al revés. El agente no toma la misma decisión en todos los casos porque la utilidad esperada cambia según el contexto.

Los sistemas de recomendación son otro caso donde esto aparece con claridad. Recomendar el contenido más popular no es lo mismo que recomendar lo que más le va a gustar a ese usuario en particular, ni tampoco es lo mismo que recomendar lo que va a hacer que el usuario pase más tiempo en la plataforma.

Son tres objetivos distintos que a veces coinciden y a veces no. Un agente basado en utilidad puede modelar esas preferencias de forma numérica y encontrar el balance que maximiza lo que realmente le importa al negocio, que casi nunca es solo una de esas tres cosas.

Agentes de aprendizaje

El agente de aprendizaje cierra la taxonomía incorporando algo que ninguno de los tipos anteriores tiene, que es la capacidad de modificar su propio comportamiento a partir de la experiencia acumulada. No trabaja con reglas fijas que alguien programó de antemano, sino que ajusta su política de acción a medida que interactúa con el entorno y recibe retroalimentación sobre los resultados.

Una de las limitaciones que impulsó el desarrollo de esta arquitectura fue precisamente el techo que mostraron los sistemas expertos. Por más sofisticado que fuera su razonamiento, su conocimiento no crecía con la experiencia. Cada caso nuevo que las reglas no contemplaban requería intervención humana para actualizar la base de conocimiento.

Figura 8. Agente de aprendizaje



Fuente: elaboración propia.

Russell y Norvig (2016) describen la arquitectura de estos agentes de aprendizaje con cuatro componentes que trabajan en conjunto:

- El elemento de desempeño es el que actúa, el que selecciona qué hacer en cada momento.
- El crítico observa esas acciones y las evalúa contra algún estándar externo, que puede ser una etiqueta provista por un humano, una señal de recompensa del entorno o una métrica de calidad predefinida.
- El elemento de aprendizaje toma esa evaluación y la usa para modificar el conocimiento del agente, ajustando lo que sabe o cómo decide.
- El generador de problemas completa el ciclo proponiendo nuevas situaciones que permitan seguir aprendiendo.

Lo importante es que el grado de autonomía varía según el mecanismo de aprendizaje que se use. En el aprendizaje supervisado, el crítico depende de etiquetas que alguien preparó previamente. En el aprendizaje por refuerzo, las señales vienen del entorno, pero la función de recompensa la diseñó un humano. En el aprendizaje no supervisado, el agente descubre estructura en los datos sin supervisión directa. Lo que tienen en común es que en ninguno de los tres casos alguien le dice explícitamente qué regla aplicar en cada situación concreta. Eso es lo que los diferencia de los tipos anteriores de la taxonomía (Raschka y Mirjalili, 2017).

Los modelos de detección de fraude en transacciones financieras son un caso concreto de aplicación. Al principio de una implementación, el agente se entrena con historiales de transacciones etiquetadas como fraudulentas o legítimas. Pero el fraude no es estático, ya que las personas que cometen fraude cambian sus métodos cuando detectan que están siendo identificadas.

Un sistema basado en reglas fijas se queda obsoleto rápido porque las reglas las conoce quien las tiene que evadir. Un agente de aprendizaje que se sigue entrenando con los casos nuevos que van

apareciendo, donde el crítico incorpora las confirmaciones de fraude que llegan con días o semanas de retraso, va ajustando su modelo a medida que los patrones cambian.

Aplicación al caso

Al comienzo de la lectura se preguntó si los robots de los almacenes de Amazon eran verdaderamente autónomos, o si eran simplemente sistemas automáticos que seguían rutas fijas entre estanterías.

Con los conceptos expuestos, la distinción es más clara. Un robot que sigue rutas predefinidas entre puntos fijos es automático. No importa qué esté pasando en el almacén; aplica el mismo recorrido, y si aparece un obstáculo no previsto, no tiene herramientas para resolverlo por su cuenta.

Los robots de Amazon Robotics hacen algo cualitativamente distinto. Perciben el estado del entorno en tiempo real, mantienen una representación interna del mapa del almacén que se actualiza continuamente y replantean su ruta cuando detectan obstáculos, otros robots o cambios en el layout.

Cuando el sistema central les asigna un objetivo, buscan activamente la secuencia de acciones que los lleva desde su posición actual hasta ese objetivo de la forma más eficiente posible. Ese ciclo continuo de percepción, procesamiento y acción es exactamente lo que define a un agente inteligente.

Sin embargo, la taxonomía que se expuso en esta lectura permite afinar aún más esa descripción. En sus tareas más simples, como detenerse ante un obstáculo inmediato, estos robots se comportan como agentes reactivos: perciben y actúan casi de forma directa, sin deliberación.

En sus tareas más complejas, como planificar el recorrido óptimo considerando el tráfico de otros robots y la urgencia de cada pedido, se comportan como agentes orientados a objetivos. No son un tipo u otro de forma excluyente: son un ejemplo claro de arquitectura híbrida, que combina una capa reactiva rápida con una capa deliberativa más lenta, exactamente el diseño que Russell y Norvig (2016) identifican como dominante en los sistemas de IA avanzada actuales.

Pero la autonomía tiene límites. Los robots no definen qué pedidos son urgentes, no deciden cómo reorganizar el almacén ni cuestionan si el criterio de eficiencia que optimizan

es el correcto. Esas decisiones las tomaron los ingenieros de Amazon. En ese sentido, son agentes autónomos dentro de un marco de objetivos y restricciones que definieron los humanos.

Lo que el caso ilustra con claridad es que la frontera entre automatización y autonomía no es binaria. Es un espectro, y los conceptos de esta lectura (arquitectura interna, tipo de entorno, tipo de agente) son las herramientas que permiten ubicar cualquier sistema en ese espectro con precisión.

Actividades de repaso de lecturas

ACTIVIDADES DE REPASO Y REFUERZO

PREGUNTAS VERDADERO/FALSO

Un agente orientado a objetivos puede perseguir distintos objetivos sin necesidad de rediseñar su razonamiento subyacente, ya que la lógica de búsqueda y planificación es independiente de la descripción del estado que se desea alcanzar.

- ○ Es verdadero, porque la separación entre el conocimiento sobre el entorno y la especificación del objetivo permite cambiar lo que el agente busca alcanzar sin modificar cómo lo busca.
- ○ Es falso, porque cada vez que cambia el objetivo, es necesario reprogramar por completo la lógica de razonamiento del agente.

Referencias

Murphy, K. P. (2022). Probabilistic machine learning: An introduction. MIT Press. https://probml.github.io/pml-book/book1.html

Raschka, S., y Mirjalili, V. (2017). Python machine learning: Machine learning and deep learning with Python, scikit-learn, and TensorFlow (2a ed.). Packt Publishing.

Russell, S., y Norvig, P. (2016). Artificial intelligence: A modern approach (3a ed.). Pearson.

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., y Wen, J. R. (2024). A survey on large language model based autonomous agents. Frontiers of Computer Science, 18(6), 186345. https://doi.org/10.1007/s11704-024-40231-1