Sistemas expertos y gestión de la incertidumbre

Introducción

En la lectura anterior se estudiaron los algoritmos de búsqueda: pudiste conocer que son herramientas poderosas, pero que operan sin comprender el dominio: no distinguen si están planificando una ruta, resolviendo un puzzle o moviendo un robot. Esa generalidad es una ventaja cuando el problema es bien definido, pero se convierte en una limitación severa cuando el dominio es complejo, parcialmente observable o intrínsecamente incierto.

> Un sistema que decide si bloquear una transacción no puede explorar todos los caminos posibles, necesita razonar con lo que tiene, actualizar sus creencias a medida que llega nueva evidencia y, en muchos contextos regulados, explicar cada decisión paso a paso.

Eso es exactamente lo que abordan los sistemas expertos, el razonamiento probabilístico y las ontologías formales, las tres grandes herramientas que se recorrerán en esta lectura.

Los sistemas expertos capturan el conocimiento de un especialista humano en reglas explícitas y lo aplican sobre situaciones concretas para derivar conclusiones. Su arquitectura separa de forma deliberada lo que el sistema sabe, cómo lo usa y cómo lo justifica. Esa separación es lo que hace posible la trazabilidad: el sistema no solo decide, sino que puede mostrar, regla por regla, por qué llegó a esa conclusión.

En el mundo real, los datos son ruidosos, la información es incompleta y muchos fenómenos son aleatorios. Para operar en esas condiciones, los sistemas inteligentes necesitan razonar con probabilidades en lugar de verdades absolutas. El teorema de Bayes es el mecanismo formal que permite actualizar creencias de forma coherente cada vez que llega nueva evidencia, y las redes bayesianas extienden esa capacidad a dominios con decenas o cientos de variables interrelacionadas.

Finalmente, cuando múltiples sistemas necesitan colaborar sobre el mismo dominio, surge el problema de la ambigüedad de significado. Las ontologías formales lo resuelven especificando explícitamente qué conceptos existen en un dominio, qué propiedades tienen y cómo se relacionan, de una forma que permite razonamiento automático e interoperabilidad entre sistemas heterogéneos.

Caso: detección de fraude en tiempo real

Supón que una fintech regional debe tomar, casi en tiempo real, una decisión sobre cada operación procesada en su plataforma: ¿es legítima o fraudulenta? En un contexto donde el volumen de transacciones electrónicas crece año tras año, esa decisión se repite millones de veces por día, y cada error tiene un costo: bloquear a un cliente legítimo daña la experiencia y la confianza; dejar pasar una operación fraudulenta tiene consecuencias financieras y regulatorias directas.

La organización comenzó su desarrollo construyendo un sistema basado en reglas. El conocimiento de sus analistas de fraude senior se codificó en reglas IF-THEN: si el monto supera tres veces el promedio histórico del cliente Y el dispositivo no fue usado en los últimos 30 días, entonces marcar como sospechosa con alta prioridad. Si la ubicación geográfica no coincide con el país de emisión de la tarjeta Y el horario es entre las 00:00 y las 05:00, entonces bloquear y solicitar verificación. El sistema funcionó razonablemente bien durante los primeros meses.

El problema apareció cuando el volumen de transacciones creció y con él la diversidad de los patrones de fraude. Las reglas comenzaron a colisionar entre sí; una transacción legítima de un cliente que viajaba al exterior se bloqueaba porque activaba tres reglas simultáneamente, mientras que un ataque coordinado de bajo monto pasaba sin ser detectado porque ninguna regla individual lo capturaba. El equipo sumaba reglas para cubrir cada caso nuevo, pero la base de conocimiento crecía de forma no lineal y cada modificación podría generar efectos inesperados en otras reglas.

El segundo desafío fue regulatorio: la normativa vigente exigía que toda decisión de bloqueo pudiera ser explicada al cliente afectado y auditada por el organismo de control. Eso descartaba cualquier modelo de caja negra y obligaba a mantener la trazabilidad del

razonamiento, convirtiendo la explicabilidad en un requisito de diseño y no en una característica opcional.

La solución que adoptó la empresa fue un sistema híbrido de tres capas.

- La primera usa un modelo de aprendizaje automático que analiza el comportamiento histórico de cada cliente y produce una puntuación de anomalía para cada transacción.
- La segunda es un motor de inferencia bayesiano que toma esa puntuación como evidencia inicial y la actualiza de forma continua a medida que llegan nuevos eventos dentro de la misma sesión.
- La tercera capa es un sistema de reglas que opera sobre esas probabilidades actualizadas; cuando la probabilidad supera un umbral configurado, aplica la política correspondiente y registra la traza completa del razonamiento para cumplir con el requisito de explicabilidad.

Para que las tres capas puedan intercambiar información sin ambigüedad, el equipo construyó una ontología del dominio financiero que define de forma unívoca conceptos como transacción, dispositivo, sesión, anomalía y perfil de cliente, con sus relaciones y propiedades formales. Sin esa ontología, cada sistema podía construir su propia interpretación del mismo concepto y los errores en la integración se volvían silenciosos y difíciles de rastrear. Con ella, cualquier componente que acceda al dominio comparte exactamente el mismo significado para cada término, independientemente de cuándo fue desarrollado o por qué equipo.

A modo de reflexión

> *Piensa en algo cotidiano. Cuando recibes un mensaje de texto que dice que ganaste un premio y que tenés que hacer clic en un enlace, ¿qué tan legítimo puede ser? Probablemente, muy poco.*
>
> *Ahora imagina que ese mismo mensaje viene del número de tu banco, menciona tu nombre completo y el último movimiento real de tu cuenta, ¿cambió tu estimación? ¿Por qué?*

Anota tu respuesta. Al terminar la lectura, vas a tener el nombre formal para cada paso de ese proceso que tu intuición ya realiza de forma natural.

Sistemas expertos

Una vez que ya sepas cómo representar conocimiento en forma de hechos, reglas e inferencia, el paso natural es construir sistemas que realmente lo usen. Los sistemas basados en reglas (SBR) hacen exactamente eso, almacenan el conocimiento en forma de reglas IF THEN y las aplican sobre una situación concreta para derivar conclusiones o ejecutar acciones. Su aplicación más ambiciosa son los sistemas expertos, que capturan el conocimiento de un especialista humano, lo codifican en esas mismas reglas y logran que una máquina razone como él lo haría.

> Es decir, que un sistema experto es un programa de inteligencia artificial diseñado para emular el razonamiento y la toma de decisiones de un especialista humano en un dominio de conocimiento específico. En esencia, captura el conocimiento de uno o varios expertos y lo codifica en reglas y estructuras lógicas para que una computadora pueda llegar a conclusiones, hacer diagnósticos o resolver problemas al nivel de un profesional.

Del SBR se toma el concepto de base de conocimiento, el motor de inferencia y los hechos del problema pasan a ser los datos del caso, pero se agregó un componente nuevo denominado módulo de explicación, que permite que el sistema justifique por qué llegó a una conclusión.

Ese detalle no es menor y retoma exactamente el argumento sobre transparencia y trazabilidad, ya que un sistema experto no solo toma la decisión, sino que puede dar cuenta de ella, regla por regla. Es la misma razón por la que estos sistemas siguen siendo la opción preferida en contextos donde una decisión afecta a una persona y alguien tiene que poder explicar el razonamiento detrás.

Arquitectura clásica de un sistema experto

La arquitectura de un sistema experto clásico separa de forma explícita tres cosas: lo que el sistema sabe, cómo lo usa y cómo explica lo que concluye. Russell y Norvig (2016) describen esta separación como uno de los rasgos más valiosos del paradigma, porque hace al sistema auditable de una manera que los modelos estadísticos modernos rara vez logran.

Tabla 1. Arquitectura de un sistema experto

Componente	Función
Base de conocimiento	Almacena el conocimiento del dominio: reglas, hechos generales, relaciones. Es el componente más costoso de construir y el más crítico para la calidad del sistema.
Memoria de trabajo	Contiene los hechos del caso actual. Cambia durante la sesión y se actualiza con los hechos que el motor de inferencia va derivando.
Motor de inferencia	Aplica las reglas sobre los hechos disponibles para derivar conclusiones. También decide qué regla aplicar cuando varias son aplicables a la vez.
Módulo de explicación	Registra la traza de inferencia: qué reglas se aplicaron, en qué orden, con qué hechos. Permite responder "¿por qué llegaste a esa conclusión?".

Fuente: elaboración propia.

El mundo real casi nunca ofrece la certeza que una regla determinista requiere. Como se estudió en la lectura anterior, MYCIN, uno de los sistemas expertos médicos más estudiados del mundo, introdujo los factores de certeza (CF) que son números entre -1 y +1 que expresan cuánta confianza hay en una hipótesis. Sus reglas tenían esa estructura:

> "SI el organismo tiene cierta morfología Y crece de determinada manera, ENTONCES la identidad probable es tal organismo, con CF = 0,7".

No era una afirmación categórica, sino una estimación con grado de confianza explícito. La lógica difusa, propuesta por Zadeh en 1965, ofrece otra forma de abordar el mismo problema. En lugar de tratar las proposiciones como verdaderas o falsas, asigna grados de pertenencia entre 0 y 1 a conjuntos difusos. Los sistemas de control difuso, muy usados en robótica e industria, aplican reglas del tipo:

> "SI la temperatura es muy alta, ENTONCES el enfriamiento debe ser muy intenso".

Sistemas expertos en la actualidad

Los sistemas expertos siguen vigentes en áreas donde sus ventajas son difíciles de reemplazar: la interpretabilidad, la auditabilidad y el comportamiento predecible. En el sector financiero, los motores de reglas para evaluación de crédito, detección de fraude y cumplimiento regulatorio procesan millones de transacciones diarias. En medicina, los sistemas de soporte a la decisión clínica integrados en registros médicos electrónicos usan bases de reglas para alertar sobre interacciones entre medicamentos y sugerir estudios diagnósticos.

Sin embargo, es importante señalar que tienen algunas limitaciones, cuyo conocimiento se vuelve fundamental para poder tomar buenas decisiones de diseño, tal como combinarlos con enfoques que compensen sus debilidades. Un patrón que funciona bien es que un modelo de aprendizaje automático maneje la percepción y clasificación de señales de baja estructura, mientras que un sistema de reglas opera sobre esas clasificaciones para razonar y generar explicaciones.

A continuación, se presentan algunas de las limitaciones que en general presentan los sistemas expertos.

Problema de escalabilidad

A medida que el dominio crece en complejidad, el número de reglas necesarias crece de forma no lineal, y el motor de inferencia debe explorar un espacio que puede volverse exponencialmente grande. Russell y Norvig (2016) identifican esta explosión combinatoria como un problema estructural que no se resuelve simplemente con más potencia computacional. Un sistema de diagnóstico completo en medicina interna necesitaría representar miles de enfermedades con cientos de síntomas posibles, resultando en millones de reglas. En ese punto, el sistema se vuelve inmanejable.

Problema del mantenimiento

Una base de conocimiento no es estática. El mundo cambia, la ciencia avanza y el sistema necesita actualizarse. En ciberseguridad, aparecen todos los días nuevas formas de ataque. Raschka y Mirjalili (2017) señalan que el mantenimiento de la base de conocimiento es uno de los costos más subestimados en el ciclo de vida de estos sistemas. Las interdependencias entre reglas hacen que modificar una pueda generar efectos en cascada sobre otras, creando inconsistencias difíciles de detectar.

Problema de adquisición de conocimiento

Este es quizás el problema fundamental. Los expertos humanos poseen varios tipos de conocimiento que no son igual de articulables. Russell y Norvig (2016) distinguen entre conocimiento declarativo (hechos que pueden enunciarse), conocimiento procedimental (cómo hacer algo, difícil de verbalizar) y conocimiento tácito (intuiciones construidas a partir de miles de casos que el experto difícilmente puede explicar en palabras). Ese conocimiento tácito es precisamente lo que el aprendizaje automático puede extraer directamente desde los datos, sin necesidad de que nadie lo verbalice.

Fragilidad ante lo inesperado

Los sistemas expertos están diseñados para operar dentro de los límites de su base de conocimiento. Si encuentran una situación no representada en sus reglas, simplemente no pueden razonar sobre ella. Bommasani, Hudson, Adeli, Altman, Arora, von Arx, Bernstein, Bohg, Bosselut, Brunskill, Brynjolfsson, Buch, Card, Castellon, Chatterji, Chen, Creel, Davis, Demszky y Liang (2021) señalan que los modelos fundacionales modernos representan un intento de superar esta fragilidad aprendiendo representaciones generales que permiten generalizar a situaciones no vistas en el entrenamiento.

Experimentación: límites del razonamiento basado en reglas

Plataforma: Registrar cuál IAG se utiliza.

Prompt 1, escalabilidad: estoy diseñando un sistema basado en reglas para [tu dominio]. ¿Cuántas reglas necesitaría aproximadamente para cubrirlo bien? ¿A partir de qué número de variables el sistema se vuelve inmanejable?

Prompt 2, casos no anticipados: describe un caso atípico de tu dominio. ¿Cómo lo manejaría un sistema de reglas? ¿Y un modelo de ML?

Prompt 3, sistemas híbridos: para [tu dominio], diseña la arquitectura de un sistema que combine reglas IF-THEN con un componente de machine learning. ¿Qué maneja cada componente? ¿Cómo se comunican?

Incertidumbre en sistemas de inteligencia artificial

Para entender el razonamiento probabilístico, conviene empezar aceptando algo que suena filosófico, pero tiene consecuencias técnicas, ya que la certeza absoluta es inalcanzable para cualquier agente que opere en el mundo real. Russell y Norvig (2016) identifican al menos cuatro fuentes de incertidumbre.

- **La primera fuente es la observabilidad parcial:** el agente no puede ver todo lo que necesitaría para tomar decisiones perfectas. Un robot con sensor LIDAR tiene zonas que no puede detectar. Un sistema que analiza tráfico de red no puede leer el contenido de los paquetes cifrados, que hoy representan la mayor parte del tráfico. Un modelo predictivo jamás va a tener acceso a todas las variables que afectan el comportamiento humano: las motivaciones, el estado de ánimo, o cosas que simplemente no están en ninguna base de datos.

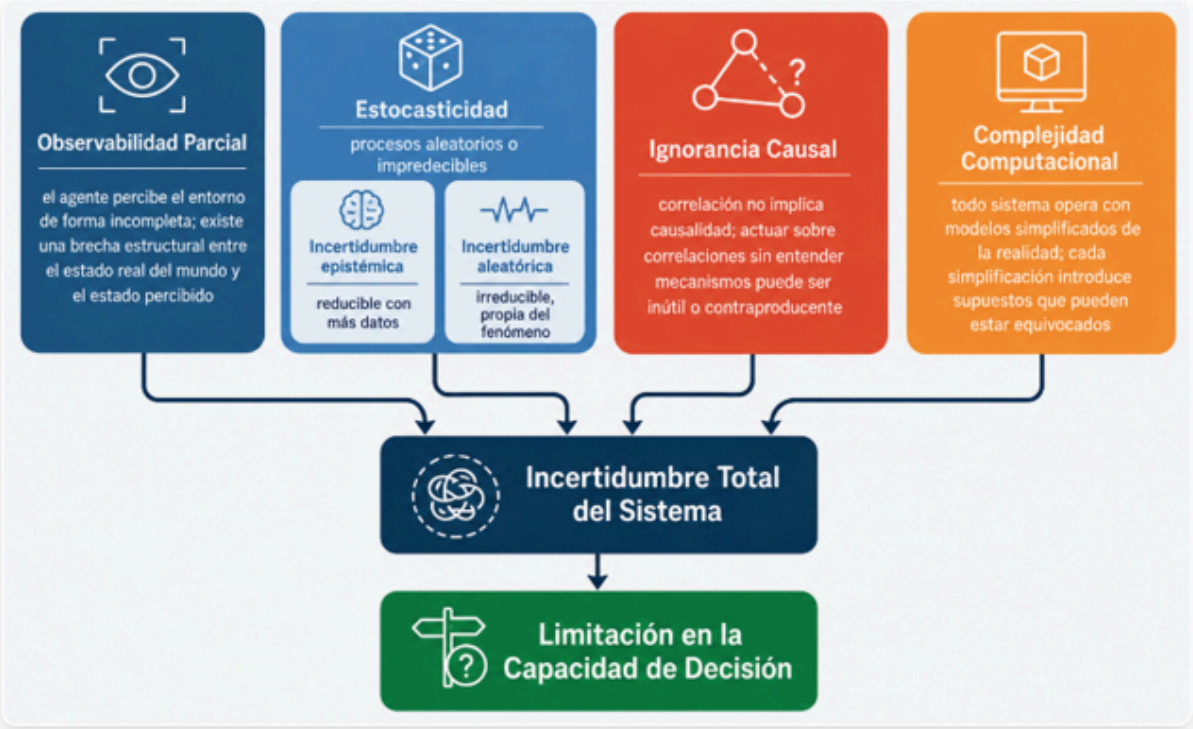
- **La segunda fuente es la estocasticidad.** Algunos procesos son genuinamente aleatorios, o dependen de tantos factores que en la práctica resultan impredecibles. Murphy (2022) distingue dos tipos de incertidumbre con consecuencias de diseño muy diferentes. La incertidumbre epistémica viene de no tener suficiente información, y puede reducirse con más datos o mejor instrumentación. La incertidumbre aleatoria es propia del fenómeno en sí y no desaparece aunque se agreguen más datos. Confundir una con la otra tiene un costo real: un sistema que trate como epistémica una incertidumbre que en realidad es aleatoria va a seguir acumulando datos sin mejorar nada.

- **La tercera fuente es la ignorancia sobre mecanismos causales.** Tener muchos datos no significa entender por qué las cosas pasan. Hay patrones genéticos correlacionados con ciertas enfermedades donde el mecanismo exacto todavía no se conoce. En plataformas digitales, saber que un usuario está por abandonar el servicio no explica si es porque la experiencia es mala, o si ambas cosas son consecuencia de algo tercero que no se está midiendo. Esa confusión entre correlación y causalidad es problemática: actuar sobre una correlación puede ser completamente inútil, o incluso empeorar la situación.

- **La cuarta fuente es la complejidad computacional.** Aunque se tuviera toda la información disponible, procesarla para cada decisión sería demasiado costoso. Por eso todo sistema práctico trabaja con versiones simplificadas de la realidad, es decir, con modelos. Y esa

simplificación trae su propia incertidumbre. Al entrenar un clasificador, se asume que los datos de entrenamiento representan bien el futuro. Al construir una red bayesiana, se asume que la estructura elegida captura las relaciones que importan. Cualquiera de esas suposiciones puede estar equivocada.

Figura 1. Fuentes de incertidumbre



Fuente: elaboración propia.

Tipos de incertidumbre

Una vez que se acepta que la incertidumbre está presente, se debe ser más preciso sobre sus formas concretas, porque cada una requiere estrategias de manejo distintas. Las tres manifestaciones más frecuentes en sistemas de IA son el ruido en los datos, la ambigüedad en las representaciones y los datos faltantes o incompletos.

El ruido es el más conocido. Es ese margen de error que aparece en las mediciones: un sensor de temperatura que oscila alrededor del valor real, o un sistema que siempre mide de más por un defecto de calibración. En datos de compras online, por ejemplo, los registros duplicados por fallas técnicas pueden confundir a un modelo que intenta detectar fraude. No porque el modelo sea malo, sino porque los datos que recibe son sucios. El modelo más sofisticado del mundo va a rendir mal si nadie limpió los datos primero.

La ambigüedad no es un problema de medición, sino de interpretación. Una misma señal puede significar cosas completamente distintas según el contexto o un fragmento de código que parece malicioso puede ser perfectamente legítimo en otro sistema. Sin más información, no hay forma de resolverlo, y forzar una respuesta es peor que admitir que no se sabe.

Los datos faltantes son los más complejos, porque no todos los vacíos son iguales. Hay tres casos:

- **Falta un dato por una razón que no tiene nada que ver con ese dato.** El sensor se apagó por un corte de luz. Ese vacío es aleatorio de verdad, y se puede manejar con técnicas simples sin introducir errores graves.

- **La ausencia depende de otras variables, pero no del dato en sí.** Cierto tipo de usuario nunca completa un campo del formulario, independientemente de cuál sería su respuesta. Acá se pueden usar métodos más elaborados y los resultados siguen siendo confiables.

- **El dato falta precisamente porque tiene un valor extremo.** En estudios clínicos, los pacientes que peor están son los que más abandonan el seguimiento, justo cuando más interesaría saber cómo evolucionaron. Ningún método estadístico resuelve eso limpiamente. Hay que asumir cosas que no se pueden verificar.

Experimentación: identificando incertidumbre

Plataforma: Registrar cuál IAG se utiliza.

Prompt sugerido: soy estudiante de [carrera]. Quiero analizar los tres tipos de incertidumbre en datos de mi campo. Para cada tipo:

1. Descríbeme un ejemplo específico de ruido en datos de mi dominio, incluyendo el impacto que tendría en un modelo si no se maneja.

2. Descríbeme un caso de ambigüedad específico de mi carrera, y qué información adicional permitiría resolverla.

3. Dame un ejemplo de datos faltantes indicando cuál de los tres mecanismos es más probable y por qué. Para cada ejemplo, indica si la incertidumbre es epistémica o aleatoria.

Para reflexionar: ¿Cuál de los tres tipos de incertidumbre es más frecuente y crítico en el campo elegido? ¿Existe alguna situación donde confundir incertidumbre aleatoria con epistémica podría tener consecuencias graves?

Teoría de probabilidades

La teoría de probabilidades es el lenguaje formal de la incertidumbre y hay dos grandes interpretaciones con consecuencias distintas. La interpretación frecuentista entiende la probabilidad como la frecuencia relativa de un evento al repetir un experimento muchas veces bajo condiciones idénticas. Es una definición objetiva y medible, pero tiene como limitación que el experimento pueda repetirse.

La interpretación bayesiana la entiende como una medida del grado de conocimiento de quien razona a partir de lo que tiene disponible:

- ✓ **Primero, permite razonar sobre eventos únicos.** Por ejemplo, si un médico necesita evaluar si un paciente específico tiene una determinada condición, no puede repetir el experimento n veces.

- ✓ **Segundo, obliga a explicitar los supuestos desde el principio,** convirtiendo supuestos que normalmente quedarían implícitos en elementos formales y verificables.

Russell y Norvig (2016) agregan algo que vale la pena destacar y es que, desde esta perspectiva, la probabilidad no describe el mundo, sino el estado de conocimiento del agente, y por eso puede

actualizarse a medida que llega nueva información.

Más allá de esta discusión interpretativa, el cálculo probabilístico descansa sobre tres axiomas matemáticos. El primero establece que toda probabilidad es un número no negativo. El segundo, que la probabilidad del espacio muestral completo es igual a 1. El tercero, que la probabilidad de la unión de eventos mutuamente excluyentes es la suma de sus probabilidades individuales. Tres reglas simples de las que se deriva toda la teoría.

Lo que resulta especialmente relevante es que estos axiomas funcionan también como criterio de coherencia. Si un sistema de creencias les asigna probabilidades que no los respetan, puede demostrarse matemáticamente que producirá decisiones sistemáticamente subóptimas. No como cuestión empírica, sino como consecuencia lógica. De ahí la importancia de trabajar dentro de este marco formal cuando se opera bajo incertidumbre.

Probabilidad condicional

La probabilidad condicional es la base del razonamiento probabilístico. Captura algo intuitivo, pero que requiere formalización para manejarse correctamente: lo que se cree sobre A cambia cuando se sabe algo sobre B, si ambos están relacionados.

La probabilidad condicional de A dado B, escrita P(A|B), se define como la probabilidad de que A y B ocurran juntos dividida por la probabilidad de B. Tiene una interpretación geométrica clara: si se sabe que B ocurrió, el espacio de posibilidades se restringe a los mundos donde B es verdadero, y dentro de ese subespacio las probabilidades se redistribuyen de forma proporcional.

Supón que en una plataforma de e-commerce la probabilidad de que un usuario cualquiera compre un producto es del 3 %, estimada a partir del historial general. Pero si ese usuario acaba de agregar el producto al carrito y pasó más de cinco minutos en la página de descripción, la probabilidad se actualiza significativamente, quizás al 40 % o más, dependiendo de lo que indiquen los datos históricos de comportamiento. La probabilidad condicional es precisamente el mecanismo que permite incorporar esa evidencia de forma matemáticamente rigurosa.

La independencia condicional merece atención especial porque es un concepto contraintuitivo con consecuencias prácticas muy importantes. Dos variables pueden estar correlacionadas entre sí, pero volverse independientes una vez que se conoce una tercera.

En el mismo contexto de e-commerce, el tiempo en página y la cantidad de imágenes vistas pueden estar correlacionados en la población general, pero ser condicionalmente independientes una vez que

se sabe que el usuario ya tiene intención de compra: conocer el tiempo en página no agrega información sobre las imágenes vistas, dado ese estado. Cuando esta propiedad existe en el dominio, permite construir modelos mucho más simples que la distribución conjunta completa, y es la base de algoritmos como Naïve Bayes.

Teorema de Bayes

El teorema de Bayes se deriva en tres líneas algebraicas a partir de la definición de probabilidad condicional. Publicado originalmente por Thomas Bayes alrededor de 1763 y formalizado por Laplace poco después, sus implicaciones conceptuales tardaron más de un siglo en ser completamente apreciadas.

El teorema establece que la probabilidad posterior de una hipótesis H, dado que se observó la evidencia E, es proporcional al producto de dos términos: la verosimilitud, es decir, cuán probable es observar E si H fuera verdadera, y la probabilidad a priori de H antes de ver E. El denominador actúa como constante de normalización para garantizar que las probabilidades posteriores sumen 1.

Lo conceptualmente relevante es que el teorema formaliza el aprendizaje como un proceso de actualización de creencias. Cada vez que se observa nueva evidencia, las probabilidades se ajustan de forma coherente y sistemática. La distribución posterior de hoy se convierte en la distribución a priori de mañana.

A medida que se acumula evidencia, cada actualización individual tiene menos impacto sobre el resultado final, y el sistema gana progresivamente mayor certeza en sus estimaciones. Russell y Norvig (2016) presentan esta estructura como la descripción formal de cómo un agente racional debe aprender, combinando lo que ya sabía con lo que acaba de observar.

En seguridad informática, los sistemas de puntuación de riesgo con enfoque bayesiano asignan a cada sesión de red una probabilidad de ser maliciosa, y la actualizan de forma continua a medida que se observan nuevos eventos. Por ejemplo, una conexión entrante comienza con una probabilidad de amenaza baja, un 2 %, simplemente porque la mayoría del tráfico legítimo supera ampliamente al malicioso. Si esa sesión realiza un escaneo de puertos, la probabilidad se actualiza al alza: ese comportamiento no es frecuente en usuarios normales, pero sí muy común en atacantes. Si inmediatamente después se registran varios intentos fallidos de autenticación, la probabilidad sube nuevamente, porque la combinación de ambos eventos es aún más característica de un ataque.

Cada observación individual podría tener una explicación inocente, pero la acumulación bayesiana de evidencia permite que el sistema alcance niveles de confianza suficientes para emitir una alerta o ejecutar un bloqueo automático, sin intervención humana y con una justificación matemáticamente trazable.

Inferencia probabilística

La inferencia probabilística es el proceso completo de usar el teorema de Bayes para responder preguntas sobre un dominio con múltiples variables interrelacionadas. Russell y Norvig (2016) distinguen varias formas de consulta probabilística con una aplicación práctica diferente.

La consulta de probabilidad a posteriori pide la distribución completa de probabilidad de una variable de interés dado lo que se observó. Es la respuesta más informativa porque preserva toda la incertidumbre; en lugar de un único valor, da la probabilidad de cada posible resultado.

La consulta MAP (Maximum A Posteriori) es más práctica cuando se necesita tomar una acción específica: ¿cuál es el valor más probable dado la evidencia? Es la respuesta que normalmente proporciona un clasificador bayesiano. Murphy (2022) señala que confiar únicamente en el estimador MAP puede ser engañoso cuando la distribución posterior es plana o multimodal. Si dos hipótesis tienen probabilidades de 0,35 y 0,33, reportar únicamente la primera oculta que la segunda es casi igual de plausible.

La inferencia marginal permite responder sobre las variables de interés eliminando las que no son relevantes, sumando sobre todos sus posibles valores. Es computacionalmente costosa en el caso

general, pero la estructura de independencia condicional que explotan las redes bayesianas permite realizarla de forma eficiente en muchos dominios.

La inferencia causal va más allá. Donde la inferencia probabilística pregunta cuál es la probabilidad de Y dado que se observa X, la causal pregunta cuál es la probabilidad de Y si se interviene activamente y se fuerza a X a tomar un valor determinado. Son preguntas distintas y pueden tener respuestas muy distintas. Murphy (2022) señala que el marco formal de los grafos causales es la herramienta apropiada para separar lo que se puede concluir a partir de la observación de lo que se puede concluir a partir de la intervención.

A modo de reflexión

> *Supón que un sistema recibe una señal inusual: un paquete de red con características anómalas, una predicción de abandono de cliente que no coincide con su historial o una lectura de sensor incompatible con el movimiento de un robot.*
>
> *¿Cómo razonaría un sistema bayesiano ante eso? ¿Qué tan probable es observar esa señal si realmente hay una anomalía, versus si es simplemente ruido? ¿Cómo cambiaría esa estimación si llegara una segunda observación en la misma dirección?*
>
> *Ese ejercicio de razonamiento es exactamente lo que formalizan las redes bayesianas: una estructura para combinar múltiples variables y evidencias de forma simultánea y coherente.*

Redes bayesianas

El teorema de Bayes es útil cuando se trabaja con una sola hipótesis y un conjunto de evidencias. Sin embargo, en los problemas reales, los sistemas inteligentes enfrentan dominios con decenas o cientos de variables interrelacionadas. Representar la distribución de probabilidad conjunta sobre todas esas variables es computacionalmente inviable. Con solo 30 variables binarias, la tabla de probabilidades conjuntas requeriría más de mil millones de entradas.

Las redes bayesianas, también llamadas grafos de creencias, son la respuesta al problema de escala que plantea trabajar con muchas variables. Russell y Norvig (2016) las definen como grafos dirigidos acíclicos donde cada nodo representa una variable aleatoria y cada arista codifica una dependencia probabilística directa. Lo que hace útil esta representación es que resulta más compacta que la distribución conjunta completa, porque aprovecha una propiedad que se cumple en la mayoría de los dominios reales y es que cada variable es directamente influenciada solo por un conjunto pequeño de otras variables.

Construir una red bayesiana implica dos pasos.

1. **El primero es definir la estructura del grafo, lo cual requiere conocimiento del dominio para identificar qué variables existen y cómo se relacionan.** Puede hacerse manualmente por expertos, aprenderse desde datos, o combinarse ambos enfoques.

2. **El segundo es estimar los parámetros,** ya sea mediante métodos frecuentistas con datos etiquetados, estimación bayesiana que incorpora conocimiento previo o consulta directa a expertos cuando los datos escasean.

Nodos, aristas y tablas de probabilidad condicional

Cada nodo representa una variable aleatoria, discreta o continua. Cada arista dirigida de A hacia B expresa que A influye directamente sobre B, es decir, conocer el valor de A modifica la distribución de probabilidad de B.

La dirección de las aristas es una convención de modelado basada en el conocimiento del dominio, no necesariamente una afirmación sobre causalidad física. Dicho esto, cuando el grafo refleja relaciones causales reales, la red resulta de más utilidad para razonar sobre intervenciones.

Cada nodo tiene asociada una tabla de probabilidad condicional que especifica su distribución dada cada combinación posible de valores de sus padres: si un nodo tiene tres padres binarios, la tabla tiene ocho filas. El número de entradas crece exponencialmente con el número de padres, lo que hace necesario mantenerlo acotado. Russell y Norvig (2016) recomiendan no superar los cinco o seis padres por nodo en redes de tamaño mediano.

En una solución de comercio electrónico, una red sencilla podría modelar la probabilidad de que un usuario complete una compra. El nodo raíz sería el historial de compras previas, que influye sobre dos

variables observables: el tiempo que el usuario pasa en la página del producto y si lo agrega al carrito. Estas dos señales alimentan un nodo de intención de compra, que a su vez determina la probabilidad de que efectivamente se realice la compra. La red permite responder preguntas, ya que la inferencia combina esa evidencia de forma coherente, ponderando cada señal según su relación con las demás variables.

Figura 2. Red bayesiana para predicción de compra



Fuente: elaboración propia.

A continuación, se presenta una tabla de probabilidad condicional del nodo 'intención de compra'. Con dos padres binarios hay cuatro combinaciones posibles, y cada una produce una probabilidad distinta. Estos valores se estiman desde datos históricos y son los que la red usa para propagar la evidencia.

Figura 3. Tabla de probabilidad condicional para intención de compra



Fuente: elaboración propia.

Con tiempo bajo y sin carrito, la probabilidad de compra es casi nula (0.03), pero con ambas señales positivas sube al 74 %. Es importante también que el carrito tiene más peso que el tiempo en página; agregar el producto sin haber pasado mucho tiempo (0.28) supera a pasar mucho tiempo sin agregarlo (0.21). Esa asimetría se captura formalmente en los parámetros de la red.

Inferencia en redes bayesianas

La inferencia en una red bayesiana puede fluir en múltiples direcciones simultáneamente, lo que las convierte en herramientas de razonamiento bidireccional.

La inferencia predictiva fluye en la dirección de las aristas, de causas conocidas hacia efectos esperados. Si se sabe que un usuario tiene historial de compras frecuentes, ¿cuál es la probabilidad de que complete una compra en esta sesión? La red propaga esa información hacia adelante y produce una estimación.

La inferencia diagnóstica fluye en sentido contrario, de efectos observados hacia causas posibles. Si ya se sabe que el usuario realizó una compra, ¿qué tan probable es que tenga un historial de compras previas, versus que sea un usuario nuevo que compra por primera vez? Esta inversión del razonamiento, de efectos a causas, es exactamente lo que formaliza el teorema de Bayes en el contexto de múltiples variables.

La inferencia intercausal ocurre cuando dos variables son causas alternativas de un mismo efecto, lo que las vuelve condicionalmente dependientes entre sí aunque no exista ninguna arista directa entre ellas. Si un usuario agrega un producto al carrito, eso puede explicarse por su historial de compras frecuentes o por el tiempo prolongado que pasó en la página. Si se confirma que tiene un historial sólido, la explicación por el tiempo en página pierde peso, porque el historial ya explica el comportamiento. Russell y Norvig (2016) señalan que este fenómeno es contraintuitivo precisamente porque en el grafo las dos causas no están conectadas, pero la observación del efecto común crea una dependencia condicional entre ellas.

En cuanto a la implementación, los algoritmos exactos como la eliminación de variables funcionan bien para redes de tamaño moderado. Para redes más complejas, la inferencia exacta es difícil de gestionar y hace necesario el uso de métodos aproximados. Murphy (2022) trata el muestreo de Monte Carlo y la propagación de creencias por paso de mensajes. En aplicaciones de tiempo real, como la navegación robótica, es muy popular porque ofrece inferencia aproximada en modelos dinámicos con un costo computacional controlable.

Ontologías

Hasta ahora se habló de incertidumbre en términos numéricos. Es decir, no se supo el valor exacto de algo, pero se puede modelar esa ignorancia con probabilidades. Hay otro tipo de incertidumbre, que las probabilidades no resuelven, y es la incertidumbre de significado.

Piensa en algo concreto, supón que una tienda online tiene su sistema de inventario, su plataforma de pagos y su sistema de logística desarrollados por proveedores distintos, en momentos distintos. Cuando el sistema de inventario dice "producto agotado", ¿eso significa lo mismo que "sin stock" para la plataforma de pagos? ¿"envío express" en logística es la misma categoría que "entrega prioritaria" en el frontend que ve el cliente? Probablemente no. Cada sistema habla su propio idioma, y aunque todos están procesando información sobre el mismo pedido, lo interpretan distinto.

Este problema se llama ambigüedad semántica y es una traba cuando quieres que sistemas heterogéneos colaboren entre sí. Las bases de datos guardan datos eficientemente, pero no guardan su significado. Un XML da estructura, pero no te dice qué implica que algo tenga esa estructura. Para eso existen las ontologías formales.

> Una ontología, en el sentido informático, es una especificación explícita de los conceptos de un dominio: qué entidades existen, qué propiedades tienen, y cómo se relacionan entre sí. Lo que la distingue de un simple glosario o diccionario es que permite razonamiento automático. Un sistema que accede a una ontología puede inferir cosas que nadie le dijo explícitamente, de la misma manera que vos podés sacar conclusiones a partir de definiciones sin que alguien te liste cada implicación posible.

Siguiendo con el ejemplo, si una ontología de comercio electrónico define que "envío express" y "entrega prioritaria" son la misma categoría conceptual, todos los sistemas que usen esa ontología quedan automáticamente alineados. No hace falta un traductor entre ellos.

RDF para representar los hechos

El modelo concreto con el que se construyen estas representaciones se llama RDF (Resource Description Framework). La idea central es que toda la información se expresa en tripletas del tipo sujeto → predicado → objeto. Cada tripleta es un hecho, por ejemplo:

- ✓ Pedido #4821 → tiene estado → Enviado.
- ✓ Pedido #4821 → contiene → Producto X.
- ✓ Producto X → pertenece a → Categoría electrónica.

Encadenando millones de estas tripletas se construye un grafo de conocimiento que puede ser consultado y se enriquece automáticamente. El truco está en que cada elemento se identifica con una URI, un identificador único universal. Si el sistema de inventario y el sistema de pagos usan la misma URI para referirse a "Producto X", están garantizando que hablan de lo mismo. Sus datos se pueden combinar sin ambigüedad.

Para consultar estos grafos existe SPARQL, que cumple un rol similar al SQL en bases de datos relacionales, pero con la capacidad de cruzar relaciones semánticas complejas. Una consulta puede preguntar, por ejemplo, qué productos de una categoría determinada tuvieron devoluciones en los

últimos 30 días y están asociados a proveedores con más de cierto índice de reclamos, navegando todo ese grafo en una sola operación.

OWL para expresar conocimiento

RDF expresa hechos sobre instancias. OWL (Web Ontology Language) expresa conocimiento sobre cómo está organizado el mundo conceptualmente. Está basado en lógica formal, y eso le da una capacidad de inferencia automática a partir de jerarquías.

Una ontología de comercio electrónico puede declarar que "devolución por defecto de fábrica" es subclase de "devolución", que a su vez es subclase de "transacción con reembolso". A partir de ahí, cualquier sistema que use esa ontología puede inferir automáticamente que una devolución por defecto de fábrica activa las mismas reglas contables que cualquier otra transacción con reembolso, sin que nadie haya programado explícitamente ese caso particular.

OWL también permite especificar propiedades lógicas entre relaciones: si "compró" es la inversa de "fue comprado por" y se sabe que el cliente A compró el producto B, el sistema puede inferir automáticamente que el producto B fue comprado por el cliente A, sin que ese segundo hecho esté almacenado en ningún lado.

La diferencia que esto marca es la distinción entre datos y conocimiento. Los datos dicen qué existe. El conocimiento codificado en OWL dice qué se puede concluir a partir de eso. En este punto es importante resaltar que construir una ontología de calidad para un dominio complejo es costoso. Requiere trabajo conjunto entre quienes conocen la lógica formal y quienes conocen el negocio, y puede llevar muchas iteraciones.

Cuando los sistemas comparten ontologías bien construidas, los beneficios se multiplican. Amazon, por ejemplo, mantiene grafos de conocimiento que conectan productos, categorías, reseñas, comportamientos de compra y datos de proveedores. Eso le permite recomendar no solo "otros que compraron esto también compraron aquello", sino razonar sobre relaciones más complejas: compatibilidad entre accesorios, reemplazos equivalentes cuando un producto se agota, o agrupación semántica de productos que ningún humano etiquetó manualmente como relacionados.

Ejercitación: explorando un grafo de conocimiento

Wikidata es uno de los mayores grafos de conocimiento colaborativos del mundo, con más de 100 millones de ítems interconectados mediante propiedades semánticas estandarizadas.

Acceder a https://query.wikidata.org/

Pasos:

1. En el panel lateral de ejemplos, filtrar por el dominio más cercano a tu carrera: "diseases" y "genes" para bioinformática; "computer security" para seguridad; "robots" o "artificial intelligence" para IA y robótica; "companies" y "startups" para innovación.

2. Seleccionar un ejemplo relevante y leer la consulta SPARQL antes de ejecutarla. ¿Qué tipo de entidad es el sujeto? ¿Qué propiedades se están consultando?

3. Ejecutar la consulta y observar los resultados. Activar la visualización gráfica y navegar interactivamente por el grafo.

Observar: cómo los identificadores únicos (números Q para entidades y números P para propiedades) permiten distinguir inequívocamente entre entidades con nombres similares. Este nivel de precisión es imposible de lograr solo con texto libre, y es la base de la interoperabilidad semántica entre sistemas heterogéneos.

IA híbrida como integración de paradigmas

Como se estudió en el módulo 1, durante décadas, los investigadores de inteligencia artificial trabajaron desde dos tradiciones que competían por financiamiento, por talento y, en cierta medida, por imponer su visión sobre qué es la inteligencia y cómo construirla.

Una tradición sostenía que la inteligencia es fundamentalmente simbólica. Si se puede representar el conocimiento en reglas y manipular esas reglas de forma lógica, se pueden construir sistemas inteligentes. De ahí vienen los sistemas expertos, los planificadores automáticos, los motores de inferencia lógica, todo lo que vimos en esta lectura. La ventaja de este enfoque es que es transparente, se puede seguir el razonamiento paso a paso y entender exactamente qué pasó. La desventaja es que alguien tiene que escribir todas las reglas, y hay conocimiento que simplemente cuesta mucho escribir.

La otra tradición apostaba por algo distinto, no programar el conocimiento, sino dejar que el sistema lo aprenda desde datos. Dentro de esta tradición hay dos grandes generaciones. La primera, que hoy se llamará aprendizaje automático tradicional, agrupa algoritmos como árboles de decisión, regresión logística o máquinas de soporte vectorial. En estos casos, un humano todavía decide qué características del dato son relevantes: para detectar si un correo es spam, alguien define que hay que mirar la frecuencia de ciertas palabras, la presencia de links, la longitud del mensaje. El algoritmo aprende a combinar esas características, pero la decisión de qué mirar la tomó una persona.

La segunda generación, el aprendizaje profundo, elimina esa etapa. Las redes neuronales ajustan millones de parámetros a partir de ejemplos y aprenden solas qué representaciones del dato son útiles, sin que nadie se lo indique. Son extraordinariamente buenas manejando datos ruidosos, ambiguos o incompletos, y escalan a dominios donde ningún experto podría escribir reglas suficientes. Pero tienen el problema opuesto al enfoque simbólico, ya que nadie entiende bien qué aprendieron ni por qué toman las decisiones que toman.

Lo que la historia terminó mostrando es que ninguno de los dos enfoques resultó suficiente por sí solo, porque ambos capturan algo importante sobre la inteligencia, y sus debilidades son exactamente complementarias: donde uno falla, el otro funciona bien. Esa es la intuición detrás de la IA híbrida.

Los modelos probabilísticos como punto de encuentro

Las redes bayesianas que se estudiaron en esta lectura ocupan un lugar interesante en este debate, porque no pertenecen del todo a ninguna de las dos tradiciones. Por un lado, tienen estructura explícita, ya que el grafo es visible, interpretable, construido con conocimiento del dominio. Por otro lado, sus parámetros pueden aprenderse desde datos en lugar de especificarse a mano. Esa combinación es exactamente lo que hace posible la integración entre paradigmas.

Un ejemplo concreto es el reconocimiento de voz en los asistentes virtuales actuales. El componente que analiza el audio y estima qué fonemas se pronunciaron es una red neuronal profunda. El componente que evalúa si una secuencia de palabras tiene sentido gramaticalmente es un modelo de

lenguaje. Y el componente que combina ambas cosas para decidir qué dijiste es un decodificador bayesiano. Tres piezas de naturaleza completamente distinta trabajando juntas y eso es un sistema híbrido.

Cómo se combinan en la práctica

No hay una única forma de construir sistemas híbridos, ya que existen varios patrones, cada uno con sus propias ventajas. El más sencillo es la cascada: primero un componente estadístico procesa los datos crudos y produce alguna clasificación o predicción, y después un sistema de reglas toma esa salida y razona sobre ella. Es modular y fácil de mantener, pero tiene un problema claro: si el primer componente se equivoca, el segundo no tiene forma de corregirlo.

Una variante es incorporar el conocimiento explícito no después del aprendizaje, sino durante. Las redes neuronales que aprenden física, por ejemplo, están entrenadas con la restricción de que sus predicciones deben respetar las ecuaciones que gobiernan el fenómeno. Eso les permite aprender bien con muchos menos datos, porque el conocimiento previo actúa como guía durante el entrenamiento.

Algo que se volvió muy visible en los últimos años son los agentes que usan herramientas. Un modelo de lenguaje grande es bueno para razonar de forma general y planificar, pero comete errores aritméticos y en ocasiones produce información incorrecta. Si en lugar de pedirle que calcule algo se delega esa tarea a una calculadora, y en lugar de pedirle que recuerde un dato se consulta directamente una base de datos, el sistema combinado es mucho más confiable que cualquiera de las dos partes por separado.

Por último, está el ajuste fino de modelos grandes con conocimiento especializado. Un modelo de lenguaje preentrenado tiene conocimiento amplio sobre muchos dominios, pero de forma imprecisa. Cuando se lo entrena adicionalmente con datos curados por expertos en un área concreta, combina la capacidad de razonamiento general con el conocimiento especializado. Ninguno de los dos componentes podría producir ese resultado solo.

Aplicación al caso

Los conceptos desarrollados a lo largo de esta lectura permiten analizar las decisiones de diseño que la compañía ficticia tomó y, más importante, entender por qué algunas de ellas eran inevitables dado el problema que enfrentaban.

La primera etapa es un sistema experto clásico. Sus analistas actuaron como fuente de conocimiento del dominio, ese conocimiento fue codificado en reglas IF-THEN, y el módulo de explicación registró la traza de cada decisión, satisfaciendo el requisito regulatorio de trazabilidad. Los problemas que aparecieron cuando el volumen creció no fueron fallas de implementación, sino limitaciones estructurales: la colisión entre reglas y el crecimiento no lineal de la base de conocimiento son el problema de escalabilidad propio del paradigma. Los ataques que el sistema no detectaba demuestran que, cuando una situación no está representada en ninguna regla, el sistema simplemente no puede razonar sobre ella.

Se pueden observar las distintas fuentes de incertidumbre que se analizaron a lo largo de la lectura. Frente a esas condiciones, la respuesta no es eliminar la incertidumbre, sino manejarla con coherencia matemática. Eso es lo que hace el motor bayesiano, parte de una estimación inicial y la actualiza cada vez que llega nueva evidencia. Como se anticipó, la evidencia acumulada tiene peso y una sola señal en sentido contrario no alcanza para revertir lo que varias señales convergentes ya establecieron.

La ontología del dominio financiero resolvió un problema concreto: tres capas desarrolladas por equipos distintos necesitaban intercambiar información sobre los mismos conceptos sin ambigüedad. Sin ella, cada componente podía construir su propia interpretación y los errores de integración se volvían silenciosos. Con RDF y OWL, las entidades quedan identificadas de forma unívoca y las jerarquías conceptuales permiten inferir implicancias que nadie programó explícitamente en cada componente por separado.

La razón por la que se eligieron las tres capas en lugar de una no fue preferencia, sino necesidad de que cada capa compense exactamente las limitaciones de las demás. Eso es lo que la IA híbrida propone, no elegir un paradigma y descartar los otros, sino asignar a cada componente la parte del problema que mejor puede resolver.

Actividades de repaso de lectura

ACTIVIDADES DE REPASO Y REFUERZO

PREGUNTAS VERDADERO/FALSO

Un sistema experto puede reemplazar completamente al experto humano en cualquier dominio, ya que su base de conocimiento almacena toda la información necesaria para razonar sobre cualquier situación posible dentro de ese campo.

- ○ Es verdadero, porque la base de conocimiento de un sistema experto está diseñada para cubrir exhaustivamente el dominio, lo que le permite razonar sobre cualquier situación que se le presente.

- ○ Es falso, porque la base de conocimiento solo contiene lo que fue explícitamente codificado. Ante situaciones no representadas en sus reglas el sistema no puede razonar, y el conocimiento tácito del experto difícilmente puede trasladarse por completo a reglas formales.

> Justificación: Los sistemas expertos capturan bien el conocimiento declarativo, pero no el tácito; intuiciones y juicios que el experto difícilmente puede articular en palabras. A eso se suma que, ante situaciones no representadas en sus reglas, el sistema directamente no puede razonar.

Referencias

Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., Bernstein, M. S., Bohg, J., Bosselut, A., Brunskill, E., Brynjolfsson, E., Buch, S., Card, D., Castellon, R., Chatterji, N., Chen, A., Creel, K., Davis, J. Q., Demszky, D., & Liang, P. (2021). On the opportunities and risks of foundation models. arXiv. https://doi.org/10.48550/arXiv.2108.07258

Murphy, K. P. (2022). Probabilistic machine learning: An introduction. MIT Press.

Raschka, S., & Mirjalili, V. (2017). Python machine learning: Machine learning and deep learning with Python, scikit-learn and TensorFlow (2.ª ed.). Packt Publishing.

Russell, S., & Norvig, P. (2016). Artificial intelligence: A modern approach (3.ª ed.). Pearson.